

004: Step-wise PPO WebShop 实验计划

背景

本文记录 StepPPO 在 WebShop 上的第一版可执行实验计划。目标是尽量复用已跑 GiGPO 实验的配置约定，同时引入新的 StepPPO trainer path。主任务为 WebShop，模型为 Qwen2.5-1.5B-Instruct，使用 grouped rollout、KL regularization 和固定频率 validation。

已恢复的 GiGPO 基线

已有三个完整 GiGPO 4GPU 日志，可作为性能和运行时间基线：

Seed	日志	状态
2026	logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260530_114442.log	250 steps 完整
2077	logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260531_004613.log	250 steps 完整
2501	logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260531_123134.log	250 steps 完整

这些日志用于比较 validation task score、success rate、text score、action validity、length behavior、timing 和资源消耗。

运行环境要求

实验从仓库根目录启动，使用准备好的 conda/Python 环境，并设置 Hugging Face、Triton、vLLM 和 Ray cache。WebShop 环境侧 CPU 压力较大，因此脚本中限制了线程数和 JVM 资源。

StepPPO 与 GiGPO 的差异

StepPPO 使用 `ver1.trainer.main_step_ppo`，启用 `actor_rollout_ref.actor.value_head`，在 old-log-probability 阶段记录 old state values，基于 immediate step rewards 计算 step GAE，并在 actor update 中加入 clipped scalar value loss。GiGPO 没有 learned critic，而是通过 step group 构造 critic-free relative step advantage。

已准备脚本

- `exps/run_webshop_step_ppo_2gpu_smoke.sh`: 正确性 smoke test。
- `exps/run_webshop_step_ppo_4gpu_paper_align_simple.sh`: 4GPU StepPPO base script。

- `exps/run_webshop_step_ppo_v1_step_norm_4gpu_paper_align_simple.sh`: v1 step-normalized 版本。
- `exps/run_webshop_step_ppo_v0_base_4gpu_paper_align_simple.sh`: v0 unnormalized step-advantage 版本。
- `exps/run_webshop_grpo_4gpu_paper_align_simple.sh`: GRPO baseline。

首轮运行顺序

单 seed 首轮运行顺序为

$\text{StepPPO-v1}_{2026} \rightarrow \text{StepPPO-v0}_{2026} \rightarrow \text{GRPO}_{2026}$.

对应 wrapper 为 `exps/run_webshop_step_ppo_v1_v0_grpo_seed2026.sh`。多 seed 扩展应等单 seed 行为明确后再进行。

已知风险

StepPPO 会比 GiGPO 多 value prediction 和 value loss 开销；如果 value loss 干扰 actor backbone，还会导致 response 更长、invalid action 更多，从而进一步拖慢 rollout generation。validation 本身也很贵，因此比较 wall-clock 时必须保持 `trainer.test_freq` 一致。