

005: Step-wise PPO 代码实现说明

结论

当前 StepPPO 是 shared-backbone actor-critic 变体。它既不是纯 GRPO, 也不是纯 GiGPO。policy loss 仍然是 PPO clipped surrogate, 但 advantage 由 GRPO-style episode signal 和 learned step-wise GAE signal 混合得到。critic 不是独立模型, 而是挂在 actor 上的 value head。

Baseline 建议

non-step baseline 使用 GRPO; step-aware baseline 使用 GiGPO。因为 GiGPO 和 StepPPO 都使用 step 信息, 所以 GiGPO 是判断 learned step value 是否有价值的更强基线。GRPO 则用于衡量 step information 本身是否带来收益。

代码入口

相关文件包括:

- `verl/trainer/main_step_ppo.py`: StepPPO 入口。
- `verl/trainer/ppo/step_ppo_trainer.py`: StepPPO trainer 和 estimator 检查。
- `verl/trainer/ppo/step_ppo_algos.py`: step GAE、episode advantage、final mixing。
- `verl/workers/actor/value_head.py`: TRL-style value head 挂载。
- `verl/workers/actor/step_ppo_actor.py`: old value collection、actor update、value loss。
- `verl/workers/step_ppo_fsdpy_workers.py`: FSDP worker 集成。
- `verl/workers/sharding_manager/step_ppo_filters.py`: rollout weight sync 前过滤 value-head 参数。

Runtime Path

一次 StepPPO iteration 的顺序为:

1. 采集 multi-turn trajectories。
2. 将 episode flatten 成 environment-step samples。
3. 重新计算 old token log probabilities。
4. 用 shared actor value head 计算 old scalar state values。

5. 计算 reference log probabilities。
6. 计算 immediate step rewards 和 episode scores。
7. 计算 episode-level group advantage 与 step-level GAE advantage。
8. 将 scalar final advantage 广播到 response token。
9. 联合更新 actor 和 value head。

Rollout 字段

实现依赖 `uid`、`traj_uid`、`step_idx`。`uid` 定义初始任务 group；`traj_uid` 区分同一任务下的不同 sampled trajectories；`step_idx` 恢复 trajectory 内时间顺序。没有 `step_idx` 时，batch rearrangement 可能静默破坏 GAE 的 temporal ordering。

Value Position

默认位置为 `pre_action_last_context_token`，对应 action 生成前最后一个 context token，用于估计 $V(s_t)$ 。`first_response_token` 和 `last_response_token` 支持 ablation，但更接近 action-conditioned value。

Advantage 与 Return

`advantages` tensor 保持 token shape，但语义是 step scalar：

$$A_{t,\ell} = A_t^{\text{final}} \cdot m_{t,\ell}.$$

`step_returns` 保持 scalar，用于监督 value head。

Actor Update

当 batch 中存在 `step_returns` 时，`StepWisePPOActor.update_policy` 会同时计算 current log probabilities 和 current values。value loss 使用 old values 与 scalar returns 做 clipped regression。policy loss 和 value loss 共享同一个 optimizer step。

语义检查

当前实现满足三个关键点：value、return、TD error 和 GAE 都在 step 维度计算；每个 action 只取一个 scalar value；scalar advantage 广播到 token 只是为了复用现有 token-level PPO loss。

当前训练快照

已有 StepPPO-v1 WebShop 日志到 step 187。相对 GiGPO，它表现为 validation reward 更低、valid action ratio 更低、response clipping 更高、gradient norm 更大。详细分析见文档 009 和 010。