

006: StepPPO Advantage Normalization 说明

符号

任务 group 记为 g , 其中包含 K 条 sampled trajectories。trajectory index 为 i , 环境 step index 为 t 。immediate reward 为 $r_{i,t}$, old state value 为 $V_{i,t}^{\text{old}}$, episode return 为

$$R_i^{\text{epi}} = \sum_t r_{i,t}.$$

Episode Advantage

episode-level advantage 沿用 GRPO。对 group g :

$$\mu_g = \frac{1}{|g|} \sum_{j \in g} R_j^{\text{epi}}, \quad \sigma_g^2 = \frac{1}{|g| - 1} \sum_{j \in g} (R_j^{\text{epi}} - \mu_g)^2.$$

trajectory scalar advantage 为

$$A_i^{\text{epi}} = \frac{R_i^{\text{epi}} - \mu_g}{\sigma_g + \epsilon}.$$

然后广播到该 trajectory 的所有 step:

$$A_{i,t}^{\text{epi}} = A_i^{\text{epi}}.$$

实现中使用 `traj_uid` 去重, 避免同一 trajectory 的多个 step 在 episode-level group 中被重复计数。

Step Advantage

step advantage 沿每个 `traj_uid` 做 GAE:

$$\delta_{i,t} = r_{i,t} + \gamma(1 - d_{i,t})V_{i,t+1}^{\text{old}} - V_{i,t}^{\text{old}},$$

$$A_{i,t}^{\text{step}} = \delta_{i,t} + \gamma\lambda(1 - d_{i,t})A_{i,t+1}^{\text{step}}.$$

value target 为

$$R_{i,t}^{\text{step}} = A_{i,t}^{\text{step}} + V_{i,t}^{\text{old}}.$$

v1 当前归一化

v1 版本在 valid step batch 上分别 whitening 两个信号:

$$\hat{A}^{\text{epi}} = \text{Whiten}_{\mathcal{B}_{\text{step}}}(A^{\text{epi}}), \quad \hat{A}^{\text{step}} = \text{Whiten}_{\mathcal{B}_{\text{step}}}(A^{\text{step}}).$$

若 z 是 valid steps 上的向量, 则

$$\text{Whiten}(z)_k = \frac{z_k - \bar{z}}{\sqrt{\text{Var}(z) + \epsilon}}.$$

最终 advantage 为

$$A_t^{\text{final}, \text{v1}} = \frac{\hat{A}_t^{\text{epi}} + w\hat{A}_t^{\text{step}}}{1 + w}.$$

该做法让两个来源在 scale 上可比，但也可能削弱原始 GRPO signal，并引入 noisy critic ordering。

v0 Base 归一化

v0 保留 episode normalization，但不 whitening step GAE：

$$A_t^{\text{final}, \text{v0}} = \frac{\hat{A}_t^{\text{epi}} + wA_t^{\text{step}}}{1 + w}.$$

它用于定位 batch-level step whitening 是否是 instability 来源。

与 GiGPO 的 traj_uid 关系

使用 `traj_uid` 不代表 StepPPO 等价于 GiGPO。StepPPO 用 `traj_uid` 做 temporal GAE 和 episode return 去重；GiGPO 用 trajectory identity 与 anchor observation 构造 comparable step groups。二者都利用 step 信息，但 credit assignment 机制不同。

后续可选版本

后续可测：按 `uid` 做 step normalization、trajectory-wise centering、按 anchor observation group normalization、mixing 后再 whitening，以及将 value target normalization 与 policy advantage normalization 分离。