

007: Baseline 与 Step 信息使用说明

核心判断

因为 StepPPO 显式使用 step reward、step ordering 和 step value function，所以最相关的 baseline 是 GiGPO，而不只是 GRPO。GiGPO 也是 step-aware，但没有 learned critic。因此关键问题是：shared-backbone learned critic 是否能优于 GiGPO 的 grouped relative step signal。

方法关系

方法	使用 step reward/order	learned critic	主要角色
GRPO	否	否	non-step baseline
GiGPO	是	否	step-aware baseline
StepPPO	是	是	learned step-aware method

GRPO 使用 episode-level grouped relative advantage。GiGPO 增加 step-level grouped relative advantage。StepPPO 保留 episode-level relative signal，但用 learned value-based GAE correction 表示 step signal。

什么叫不使用 Step 信息

如果一个方法忽略 immediate step reward、step order 和 anchor observation，只使用 episode-level outcome，那么它就是 non-step 方法。即使工程上把 episode flatten 成 step samples，只要每个 step 都拿同一个 episode-level signal，它仍然属于 non-step baseline。按这个定义，GRPO 是最干净的 non-step baseline。

为什么 Classic PPO 不是干净 Baseline

classic PPO 加 critic 后可能在 token/sample 维度上学习 value，这在 agentic setting 中会不严格地引入部分 step 结构，同时又不满足我们定义的 environment-step value。因此它不如 GRPO 适合作为 no-step 对照。

推荐实验矩阵

- Non-step baseline: GRPO。
- Step-aware critic-free baseline: GiGPO。
- Learned step-aware method: StepPPO-v1 和 StepPPO-v0。

- Ablation: no step term、detached value backbone、lower value coefficient、mixing 后 final-advantage normalization。

No-Step-Advantage Ablation

直接 ablation 是设置 $w_{\text{step}} = 0$:

$$A_t^{\text{final}} = A_t^{\text{epi}}.$$

如果仍训练 value head 但 policy 不使用 step term, 可以隔离 value regression 对 shared backbone 的干扰; 如果完全关闭 value head, 则更接近 GRPO 数据路径。

结论

GRPO 用于衡量 step information 是否有收益; GiGPO 用于判断 StepPPO 的 learned critic 是否优于已有 step-aware critic-free 方法。不能只用 GRPO 作为 StepPPO 的主要 baseline。