

008: StepPPO 实验重规划与版本定义

目标

GiGPO baseline 已经完成三个 seed。GRPO 需要作为额外 non-step baseline 跑一遍。StepPPO 第一阶段准备两个版本：v1，即当前 step-normalized 版本；v0，即不对 step advantage 做 normalization 的 base 版本。

共同定义

episode advantage 为

$$A_t^{\text{epi}} = \frac{R_t^{\text{epi}} - \mu_g}{\sigma_g + \epsilon}.$$

step GAE advantage 为

$$\delta_t = r_t + \gamma(1 - d_t)V_{t+1}^{\text{old}} - V_t^{\text{old}}, \quad A_t^{\text{step}} = \delta_t + \gamma\lambda(1 - d_t)A_{t+1}^{\text{step}}.$$

value target 为

$$R_t^{\text{step}} = A_t^{\text{step}} + V_t^{\text{old}}.$$

v1: Step-Normalized 版本

当前 v1 版本在 valid step batch 上分别 normalize 两个信号：

$$\hat{A}_t^{\text{epi}} = \text{Whiten}_{\mathcal{B}}(A_t^{\text{epi}}), \quad \hat{A}_t^{\text{step}} = \text{Whiten}_{\mathcal{B}}(A_t^{\text{step}}).$$

最终 advantage 为

$$A_t^{\text{final}, \text{v1}} = \frac{\hat{A}_t^{\text{epi}} + w\hat{A}_t^{\text{step}}}{1 + w}.$$

该版本测试 scale-balanced episode signal 与 step critic signal 的组合。

v0: 不归一化 Step Advantage

v0 保留 episode normalization，但直接混合 raw GAE step advantage：

$$A_t^{\text{final}, \text{v0}} = \frac{\hat{A}_t^{\text{epi}} + wA_t^{\text{step}}}{1 + w}.$$

对应配置为 `algorithm.step_ppo.normalize_step_advantage=False`。该版本用于定位 batch-level step whitening 是否导致不稳定。

GRPO Baseline

GRPO 只使用 episode-level relative advantage:

$$A_i^{\text{GRPO}} = \frac{R_i^{\text{epi}} - \mu_g}{\sigma_g + \epsilon}.$$

它不使用 step reward、step order、step grouping 或 learned critic，是干净的 non-step baseline。

批量运行顺序

首轮只使用 seed 2026:

$$\text{StepPPO-v1}_{2026} \rightarrow \text{StepPPO-v0}_{2026} \rightarrow \text{GRPO}_{2026}.$$

对应脚本为 `exps/run_webshop_step_ppo_v1_v0_grpo_seed2026.sh`。

实现要求

v0 和 v1 应通过 wrapper script 和配置开关实现，不直接修改 baseline 脚本。实验名必须体现版本号，方便从 logs 和 W&B 中区分。

后续扩展

单 seed 行为明确后，再扩展 seed 2077 和 2501。如果 v1 继续不稳定，优先测试 detach value backbone、lower value coefficient、mixing 后 final-advantage whitening，以及仅用于 debug 的 lower validation frequency。