

009: StepPPO-v1 不稳定性与效果偏弱分析

主要现象

已有 StepPPO-v1 run 明显弱于 GiGPO seed 2026。在可对齐的 validation step 上, StepPPO 的 task score、success rate 和 text score 都更低; 同时 valid action ratio 更低、response clipping 更高、gradient norm 更大。这说明 learned value correction 目前没有改善 credit assignment, 反而可能引入优化噪声并破坏 actor 表征。

当前算法形式

v1 final advantage 为

$$A_t^{\text{final,v1}} = \frac{\hat{A}_t^{\text{epi}} + w\hat{A}_t^{\text{step}}}{1 + w},$$

其中

$$\hat{A}_t^{\text{epi}} = \text{Whiten}(A_t^{\text{epi}}), \quad \hat{A}_t^{\text{step}} = \text{Whiten}(A_t^{\text{step}}).$$

step term 来自 shared-backbone GAE:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t), \quad A_t^{\text{step}} = \delta_t + \gamma \lambda A_{t+1}^{\text{step}}.$$

默认 value-head 配置允许 value loss 更新 actor backbone:

`detach_value_backbone=False, value_loss_coef=0.1.`

诊断证据

StepPPO-v1 的 valid action ratio 明显低于 GiGPO:

$$\text{valid_action_ratio}_{\text{StepPPO}} \approx 0.803, \quad \text{valid_action_ratio}_{\text{GiGPO}} \approx 0.980.$$

response clipping 也明显更高:

$$\text{clip_ratio}_{\text{StepPPO}} \approx 0.0259, \quad \text{clip_ratio}_{\text{GiGPO}} \approx 0.0043.$$

StepPPO value loss 长期较大且波动, mean 约为 3.6, observed max 超过 8。actor grad norm 也更高:

$$\text{grad_norm}_{\text{StepPPO}} \approx 10.1, \quad \text{grad_norm}_{\text{GiGPO}} \approx 5.8.$$

这些现象更像 policy-format 退化, 而不是纯 validation 随机波动。

可能原因排序

1. **value loss 干扰 shared actor backbone**。WebShop 的 value target 高方差，value gradients 会更新 action generation 所依赖的同一套表征。
2. **v1 advantage mixture 可能削弱 policy signal**。两个 signal 都 whitening 后再平均，可能降低 effective policy-gradient scale，而 value regression 仍然存在。
3. **critic 早期不准**。当 $V(s_t)$ 质量较差时，TD error 会给出错误 step credit。
4. **batch-level step whitening 语义不匹配**。它没有像 GiGPO 那样尊重 task group、trajectory 或 anchor-state comparability。

下一轮建议

优先级如下：

1. 跑 v0-base，隔离 step-advantage normalization 的影响。
2. 跑 detach_value_backbone=True 版本。
3. 将 value_loss_coef 从 0.1 降到 0.03 或 0.01。
4. 改为 mixing 后再 normalization。
5. 增加 value target scale、value prediction scale、explained variance、episode/step advantage correlation 等日志。

结论

当前 StepPPO-v1 更适合作为 diagnostic implementation，而不是更强方法。下一步应先降低 value head 对 shared backbone 的干扰，再扩展多 seed。