

# 013: 当前项目进展与 Value 收敛分析

2026-06-09

本文记录当前 `verl-agent` 项目的实验进展, 并重点分析 StepPPO / GiGPO value-aux 方向中 value head 的收敛情况。分析基于当前仓库内的脚本、文档和 console log, 不引入外部结果。

## 1. 当前项目进展

当前项目主线已经从单纯复现 GiGPO baseline, 推进到 StepPPO 及 shared value head 的稳定性诊断阶段。

### 1.1 已完成或已有有效日志的实验

| 实验                                        | 日志                                                                            | 状态                    | 关键结论                                                                                                 |
|-------------------------------------------|-------------------------------------------------------------------------------|-----------------------|------------------------------------------------------------------------------------------------------|
| GiGPO seed 2026                           | logs/webshop_gigpo_qwen25-72b-gpt4o-paper_align_simple_20260530_114442k.log   | 完整                    | 最终 20260530_004618.log<br>0.903/0.812/7.963<br>success/text =                                        |
| GiGPO seed 2077                           | logs/webshop_gigpo_qwen25-72b-gpt4o-paper_align_simple_20260530_004618.log    | 完整                    | 最终 20260530_004618.log<br>0.883/0.754/7.341                                                          |
| GiGPO seed 2501                           | logs/webshop_gigpo_qwen25-72b-gpt4o-paper_align_simple_20260530_023134.log    | 完整                    | 最终 20260530_023134.log<br>0.869/0.691/6.952                                                          |
| StepPPO-v1 step_norm seed 2026            | logs/webshop_step_ppo_qwen25-72b-gpt4o-paper_align_simple_20260604_000227.log | 收到 15h 48m / paper 85 | 明显下降, 20260604_000227.log<br>value loss 较大, v1<br>不稳定性已记录于<br>EXPS/009_step_ppo_instability_analysis |
| StepPPO-v2 seed 2026                      | logs/webshop_step_ppo_qwen25-72b-gpt4o-paper_align_simple_20260605_030621.log | 完整                    | 相比 v1, 20260605_030621.log<br>缓和, 但 valid action ra-<br>tio 低, validation 仍未追<br>上 GiGPO             |
| GiGPO-v1 value-aux detach=false seed 2026 | logs/webshop_gigpo_v1_value_detach_false_20260605_030621.log                  | 收到 15h 48m / paper 85 | 相比 v1, 20260605_030621.log<br>GiGPO, 但 auxiliary<br>value loss 仍带来明显退化<br>和局部崩盘                      |

三个 GiGPO baseline 已形成较稳定参照: step 250 的平均 task score 约 0.885, 平均 success rate 约 0.752, 平均 text score 约 7.419。StepPPO-v1/v2 和 GiGPO-value-aux 目前都没有达到该水平。

### 1.2 当前算法与脚本状态

- StepPPO-v1 使用 `normalize_episode_advantage=True, normalize_step_advantage=True, step_advantage_w=1.0, value_loss_coef=0.1`, 且 `detach_value_backbone=False`。

- StepPPO-v2 实际脚本为 `exps/run_webshop_step_ppo_v2_4gpu_paper_align_simple.sh`, 核心配置是 `step_advantage_w=0.5`、`episode_mode=mean_norm`、`final_advantage_mode=direct`、`normalize_episode_advantage=True`、`normalize_final_advantage=False`、`value_loss_coef=0.03`、`detach_value_backbone=False`、`ppo_micro_batch_size_per_gpu=8`。
- GiGPO-v1 value-aux 由 `verl/trainer/ppo/gigpo_v1_value_aux_trainer.py` 接入: policy advantage 仍是原 GiGPO, 额外把 StepPPO-style `step_returns` 塞给 shared value head 做 auxiliary regression。
- `exps/run_webshop_gigpo_value_aux_ablation_grpo_seed2026.sh` 已规划 `detach_false -> detach_true` -> GRPO 的 batch ablation, 但当前有效 full/long 日志主要是 `detach_false`; 没有看到正式完整 4GPU GRPO baseline 日志。
- `EXPS/tex/011_step_ppo_v2_improvements.tex` 中早期叙述曾提到 detach value backbone; 但以当前脚本、日志和 `EXPS/tex/012_step_ppo_v2_paper_method.tex` 为准, 当前 v2 是 `detach_value_backbone=False`。

## 2. Validation 进展概览

| 实验                                        | val last step | best task | last task/success/-<br>text | step 200 task/suc-<br>cess/text |
|-------------------------------------------|---------------|-----------|-----------------------------|---------------------------------|
| GiGPO seed 2026                           | 250           | 0.905     | 0.903 / 0.812 / 7.963       | 0.858 / 0.719 / 7.286           |
| GiGPO seed 2077                           | 250           | 0.912     | 0.883 / 0.754 / 7.341       | 0.841 / 0.719 / 6.314           |
| GiGPO seed 2501                           | 250           | 0.897     | 0.869 / 0.691 / 6.952       | 0.812 / 0.668 / 6.362           |
| StepPPO-v1 seed 2026                      | 185           | 0.766     | 0.703 / 0.492 / 3.866       | NA                              |
| StepPPO-v2 seed 2026                      | 250           | 0.806     | 0.662 / 0.547 / 3.485       | 0.562 / 0.469 / 3.000           |
| GiGPO-v1 value-aux detach=false seed 2026 | 200           | 0.802     | 0.545 / 0.398 / 2.950       | 0.545 / 0.398 / 2.950           |

结论: 当前 value-head 相关实验还没有证明收益。StepPPO-v2 的 best task score 到过 0.806, 但最终回落到 0.662; GiGPO-value-aux best task score 到过 0.802, 但在 step 180-185 出现严重 validation collapse, step 200 仍明显低于原 GiGPO。

## 3. Value 收敛情况

### 3.1 总体判断

当前 value head 还不能认为已经稳定收敛。原因有三点:

1. `actor/value_loss` 没有形成单调下降或低方差平台; 多个实验中后期仍在 3-5 左右波动。
2. `actor/value_pred_mean` 和 `actor/value_return_mean` 的均值差距已经不大, 但这只说明均值校准有所改善, 不代表 per-sample value regression 收敛; value loss 仍然较高, 说明 target 方差或 outlier 仍很强。

3. value loss 与 policy/format 指标存在同步异常：StepPPO-v2 的 value loss 后期下降，但 valid action ratio 长期偏低；GiGPO-value-aux 保持较高 valid action ratio，却在 step 178-185 出现 response clipping 和 validation 崩盘。

### 3.2 分段 value 指标

| 实验                           | step 段  | value_loss | abs(pred-return mean) | value_clipfrac | valid_action_ratio |
|------------------------------|---------|------------|-----------------------|----------------|--------------------|
| StepPPO-v1                   | 1-50    | 1.816      | 0.226                 | 0.054          | 0.671              |
| StepPPO-v1                   | 51-100  | 3.568      | 0.291                 | 0.104          | 0.780              |
| StepPPO-v1                   | 101-150 | 4.948      | 0.376                 | 0.103          | 0.872              |
| StepPPO-v1                   | 151-187 | 4.276      | 0.290                 | 0.110          | 0.918              |
| StepPPO-v2                   | 1-50    | 2.988      | 0.416                 | 0.033          | 0.313              |
| StepPPO-v2                   | 51-100  | 3.918      | 0.397                 | 0.117          | 0.156              |
| StepPPO-v2                   | 101-150 | 3.773      | 0.315                 | 0.100          | 0.337              |
| StepPPO-v2                   | 151-200 | 4.254      | 0.375                 | 0.138          | 0.277              |
| StepPPO-v2                   | 201-250 | 2.797      | 0.283                 | 0.086          | 0.328              |
| GiGPO-value-aux detach=false | 1-50    | 5.098      | 0.484                 | 0.078          | 0.917              |
| GiGPO-value-aux detach=false | 51-100  | 6.246      | 0.465                 | 0.161          | 0.921              |
| GiGPO-value-aux detach=false | 101-150 | 4.831      | 0.444                 | 0.129          | 0.929              |
| GiGPO-value-aux detach=false | 151-200 | 4.573      | 0.399                 | 0.126          | 0.877              |
| GiGPO-value-aux detach=false | 201-204 | 4.426      | 0.507                 | 0.106          | 0.883              |

### 3.3 Last-10 value 状态

| 实验                           | last-10 step | value_loss | abs(pred-return mean) | value_clipfrac | value loss 实际项 | pg_loss | valid_action_ratio |
|------------------------------|--------------|------------|-----------------------|----------------|----------------|---------|--------------------|
| StepPPO-v1                   | 178-187      | 3.552      | 0.243                 | 0.098          | 0.355          | -0.005  | 0.935              |
| StepPPO-v2                   | 241-250      | 3.011      | 0.380                 | 0.093          | 0.090          | -0.085  | 0.281              |
| GiGPO-value-aux detach=false | 195-204      | 4.207      | 0.336                 | 0.089          | 0.126          | -0.254  | 0.908              |

这里的 value loss 是  $\text{actor/value\_loss} * \text{actor/value\_loss\_coef}$  的近似均值。v1 因为  $\text{value\_loss\_coef}=0.1$ ，后期 value 项约 0.355，数值上远大于 policy loss 均值；v2 和 value-aux 降到 0.03 后，value 项降到 0.09–0.13，但仍可能通过 shared backbone 影响 policy representation。

## 4. 关键诊断

### 4.1 StepPPO-v1: value loss 对 backbone 干扰偏强

v1 的 value loss 从 early stage 的 1.816 上升到 101–150 的 4.948，后期仍在 4 左右。由于  $\text{value\_loss\_coef}=0.1$  且  $\text{detach\_value\_backbone}=\text{False}$ ，value regression 会直接更新 actor backbone。结合 v1 validation 明显弱于 GiGPO，可以认为 v1 的 value 学习既没有稳定收敛，也可能干扰了 policy 的 action-format 能力。

### 4.2 StepPPO-v2: value loss 后期有所缓和，但 policy 行为仍异常

v2 把 value 系数降到 0.03，并对齐 GiGPO 的 episode advantage 形式。value\_loss 在 201–250 段降到 2.797，比 151–200 段的 4.254 好；但 valid action ratio 长期只有 0.15–0.33，远低于 GiGPO 和 value-aux 的 0.9 左右。因此 v2 的主要瓶颈不只是 value 是否拟合，而是 final advantage / shared-backbone update 后造成了 policy action format 退化。

### 4.3 GiGPO-value-aux: policy advantage 不变仍会退化

GiGPO-value-aux 的设计是保持 GiGPO policy advantage 不变，仅新增 value auxiliary target。按理说它应当接近 GiGPO baseline；但实际 step 200 的 task/success/text 只有 0.545/0.398/2.950，而原 GiGPO seed 2026 step 200 是 0.858/0.719/7.286。

这说明退化可以仅由 shared value head 的辅助损失引入，不一定来自 StepPPO 的 mixed advantage。尤其在 step 178–185 附近，GiGPO-value-aux 出现明显异常：

| step | value_loss | value_clipfrac | valid_action_ratio | response_clip_ratio | validation 附近表现                           |
|------|------------|----------------|--------------------|---------------------|-------------------------------------------|
| 178  | 8.230      | 0.253          | 0.700              | 0.307               | 即将崩盘                                      |
| 179  | 11.031     | 0.345          | 0.653              | 0.352               | 即将崩盘                                      |
| 180  | 6.752      | 0.125          | 0.746              | 0.252               | val task/success/text = 0.153/0.074/0.560 |
| 185  | 6.169      | 0.202          | 0.778              | 0.216               | val task/success/text = 0.155/0.102/0.798 |

该现象提示 value target 的高方差或 clipped value update 的大幅波动，会通过 shared backbone 影响生成分布；即使 valid action ratio 很快恢复，validation 也可能出现短时严重退化。

## 5. 当前结论

1. GiGPO baseline 已经稳定，仍是当前最强对照。
2. StepPPO-v1 的 value head 没有收敛到可靠 critic，且 value loss coefficient 偏大，干扰风险最高。

3. StepPPO-v2 降低了 value loss 的有效权重，后期 value\_loss 有改善，但 action-format 学习明显退化，最终效果仍弱于 GiGPO。
4. GiGPO-value-aux detach=false 证明：只加 auxiliary value loss，也足以显著破坏 GiGPO；因此当前首要问题是 shared value head / target / backbone gradient 的稳定性，而不是只调 StepPPO advantage mix。
5. 仅看 value\_pred\_mean 与 value\_return\_mean 的均值接近会过于乐观；需要看 RMSE、explained variance、target 分布和 per-step / per-validity 分层误差。

## 6. 建议下一步

### 6.1 必跑 ablation

1. 补跑 GiGPO-v1 value-aux detach=true 的 full run。若 detach=true 明显接近原 GiGPO，则可以确认主要问题来自 value loss 回传 backbone。
2. 补齐正式 GRPO seed=2026 baseline，以便区分 non-step baseline、GiGPO step-aware baseline、StepPPO/value-aux 的差异。
3. 对 StepPPO-v2 增加 detach\_value\_backbone=True 或更低 value\_loss\_coef=0.01 的 ablation；这不一定作为最终方法，但可以定位干扰来源。

### 6.2 必加 value diagnostics

建议在训练日志中新增以下 value 诊断：

- actor/value\_rmse、actor/value\_mae、actor/value\_explained\_variance。
- actor/value\_pred\_std、actor/value\_return\_std、actor/value\_return\_p05/p50/p95。
- 按 step\_idx 分桶的 value loss / return mean / return std。
- 按 is\_action\_valid 分层的 value loss，确认 invalid action penalty 是否造成 target outlier。
- value loss 与 response\_length/clip\_ratio、episode/valid\_action\_ratio 的 rolling correlation。

### 6.3 可能的稳定化方向

- 对 value target 做 batch 或 group-level normalization，只把 normalized return 用于 value loss；policy advantage 是否归一化另行控制。
- 降低或 warmup value\_loss\_coef，例如从 0 到 0.01 / 0.03 线性 warmup，避免早期 value target 噪声破坏 backbone。
- 比较 detach\_value\_backbone=True 与 False，确认最终方法是否真的需要 value loss 更新 LM backbone。
- 对 GAE target 做 clipping 或 reward normalization，尤其关注 WebShop sparse/invalid penalty 混合后的 return outlier。
- 在可视化中叠加 value\_loss、response\_clip\_ratio、valid\_action\_ratio 和 validation task score，重点复盘 GiGPO-value-aux step 170-190 的崩盘窗口。

## 7. 本文使用的解析口径

- 训练行: 包含 `actor/value_loss` 的 `step:<global_step> - ... console metric` 行。
- validation 行: 包含 `val/success_rate`、`val/webshop_task_score` (not `success_rate`) 或 `val/text/test_score` 的 `metric` 行。
- `abs(pred-return mean)`: `abs(actor/value_pred_mean - actor/value_return_mean)` 的分段均值, 只反映均值校准, 不等价于 per-sample RMSE。
- `value loss` : `actor/value_loss * actor/value_loss_coef`, 用于粗略观察 `value loss` 在总 `actor loss` 中的数值量级。