

014: StepPPO-v3 Method: Value Head on GiGPO

2026-06-09

一句话定义

当前分支里的 StepPPO-v3 就是一个 value-head-only 实验：在 GiGPO 训练上加一个 actor-side shared value head，训练它去拟合 step-level value/return，同时确认它不会影响 GiGPO 原本的 policy 训练。

这不是新的 policy algorithm，不默认引入 pure step advantage、action-level PPO ratio、step_ppo_v3 estimator、separate critic 或额外 reward shaping。v3 的问题只有两个：

1. value head 能不能稳定学出来；
2. 加了 value head 后，GiGPO 的训练行为会不会变差。

和 v2 的关系

StepPPO-v2 中最值得单独验证的部分是 shared actor value head。v3 保留这个核心点，但不把 policy advantage 同时换掉，也不把 value loss 默认回传 actor backbone。这样做是为了隔离 value head 本身：如果 value head 都学不稳，或者会拖垮 GiGPO，那么后续更复杂的 StepPPO 设计没有意义。

训练对象

给定一个 WebShop step sample，actor backbone 产生 hidden states，value head 在 action 前的 context boundary 上预测一个 scalar：

```
b_i = full_sequence_length_i - response_length_i - 1
V_i = value_head(hidden_state_i[b_i])
```

主线默认：

```
actor_rollout_ref.actor.value_head.enable=True
actor_rollout_ref.actor.value_head.detach_value_backbone=True
actor_rollout_ref.actor.value_head.value_loss_coef=0.03
actor_rollout_ref.actor.value_head.cliprange_value=0.5
```

detach_value_backbone=true 的含义是：value loss 只训练 value head，不通过 value regression 更新 actor backbone。GiGPO policy gradient 仍然按原路径更新 actor。

Policy 保持 GiGPO 不变

v3 主线必须保持：

```
algorithm.adv_estimator=gigpo
algorithm.gigpo.step_advantage_w=1.0
algorithm.gigpo.mode=mean_norm
actor_rollout_ref.actor.policy_loss.loss_mode=vanilla
```

也就是说，policy advantage、policy loss、rollout group 语义和 GiGPO baseline 保持一致。value head 是 auxiliary head，不参与当前 policy advantage 计算。

Value Target

value head 的 target 使用 step-level GAE return。当前可复用 GiGPO-v1 value-aux trainer 中的路径：从 raw per-step reward 构造 value 用的 immediate reward，再调用 StepPPO-style GAE：

```
R_i = GAE_return(reward_i, V_i, traj_uid, step_idx)
```

主线配置：

```
algorithm.gigpo_v1_value_aux.value_target=gae_returns
algorithm.gigpo_v1_value_aux.step_gamma=0.95
algorithm.gigpo_v1_value_aux.step_lam=0.90
```

invalid action penalty 只能扣一次。建议保留 value_step_rewards 字段来标记 value target 使用的 reward 口径，避免和 GiGPO 自身 step reward 语义混淆。

Value Loss

value loss 是 step scalar loss：

```
values_clipped = old_values + clamp(current_values - old_values,
                                   -cliprange_value, cliprange_value)
value_loss = 0.5 * mean(max(
    (current_values - step_returns) ** 2,
    (values_clipped - step_returns) ** 2,
))
```

总 loss 仍然是 GiGPO policy loss 加一个 auxiliary value loss：

```
loss = gigpo_policy_loss + value_loss_coef * value_loss
```

由于主线 detach backbone，auxiliary value loss 不应改变 actor backbone 的梯度方向。

必须记录的指标

只看 actor/value_loss 不够，v3 必须记录：

```
actor/value_loss
actor/value_clipfrac
actor/value_rmse
```

```
actor/value_mae
actor/value_explained_variance
actor/value_pred_mean
actor/value_pred_std
actor/value_return_mean
actor/value_return_std
actor/value_loss_coef
```

同时必须和 GiGPO baseline 对比 policy 行为:

```
episode/valid_action_ratio
response_length/mean
response_length/clip_ratio
actor/pg_loss
actor/grad_norm
val/success_rate
val/webshop_task_score (not success_rate)
```

成功标准

v3 成功不要求立刻超过 GiGPO。最低标准是:

1. value RMSE/MAE 稳定, 不随训练发散;
2. value explained variance 从接近 0 向正值移动, 说明 value head 学到有用 signal;
3. 加 value head 后, GiGPO 的 valid action ratio、response length、clip ratio 和 validation score 不明显回退;
4. detach=true 主线不复现 detach=false value-aux 那种 validation collapse;
5. actor grad norm 不因为 value loss 明显异常。

实验脚本

主线脚本:

```
exps/run_webshop_step_ppo_v3_value_head_4gpu_paper_align_simple.sh
```

这个脚本名保留 StepPPO-v3, 是研究命名; 实现含义就是 GiGPO + detached value head。

不属于当前 v3 的内容

以下内容不要写成 v3 默认设计:

- 新增 `algorithm.adv_estimator=step_ppo_v3`;
- pure step advantage 替代 GiGPO advantage;
- action-level PPO ratio 或 sequence geometric ratio;
- separate critic model;

- value loss 默认回传 actor backbone;
- 一边改 policy, 一边评估 value head 是否可行。