

015: StepPPO-v3 Algorithm Changes

2026-06-09

Scope

当前 StepPPO-v3 的工程改动只服务一个目标：在 GiGPO 训练中加入 shared value head，验证 value head 是否能稳定学习 step-level return，并确认它不影响 GiGPO policy 训练。

因此 v3 的默认改动不是新 estimator，不是新 advantage，不是 action-level PPO。v3 默认改动表如下：

模块	GiGPO baseline	StepPPO-v3 当前分支
policy advantage	GiGPO	不变
policy loss	vanilla token-level PPO path	不变
rollout group	GiGPO group	不变
actor model	actor LM	actor LM + value head
value target	无	step GAE return
value gradient	无	默认只更新 value head
验收目标	policy performance	value 稳定学习且不伤 policy

复用的现有路径

当前 v3 应复用已有 GiGPO-v1 value-aux 路径：

```
verl/trainer/ppo/gigpo_v1_value_aux_trainer.py
examples/gigpo_v1_value_aux_trainer/run_webshop.sh
verl/workers/actor/value_head.py
verl/workers/actor/step_ppo_actor.py
verl/workers/gigpo_v1_value_aux_fsdg_workers.py
verl/workers/sharding_manager/step_ppo_filters.py
```

关键逻辑：

1. trainer 保持 `algorithm.adv_estimator=gigpo`;
2. trainer 构造 value head 的 step GAE return，并写入 `data.batch["step_returns"]`;
3. actor 看到 `step_returns` 后启用 auxiliary value loss;
4. sharding manager 同步 rollout 权重时过滤 `value_head.*`。

新增脚本

新增主线脚本:

```
exps/run_webshop_step_ppo_v3_value_head_4gpu_paper_align_simple.sh
```

核心 overrides:

```
algorithm.adv_estimator=gigpo
algorithm.gigpo.step_advantage_w=1.0
algorithm.gigpo.mode=mean_norm
algorithm.gigpo_v1_value_aux.value_target=gae_returns
algorithm.gigpo_v1_value_aux.step_gamma=0.95
algorithm.gigpo_v1_value_aux.step_lam=0.90
actor_rollout_ref.actor.value_head.enable=True
actor_rollout_ref.actor.value_head.detach_value_backbone=True
actor_rollout_ref.actor.value_head.value_loss_coef=0.03
actor_rollout_ref.actor.value_head.cliprange_value=0.5
```

新增指标

需要在 `verl/workers/actor/step_ppo_actor.py` 中补充 value diagnostics:

```
value_error = current_values - step_returns
value_rmse = sqrt(mean(value_error ** 2))
value_mae = mean(abs(value_error))
value_explained_variance = 1 - var(step_returns - current_values) / var(step_returns)
```

训练日志应出现:

```
actor/value_rmse
actor/value_mae
actor/value_explained_variance
actor/value_pred_std
actor/value_return_std
```

这些指标用于判断 value head 是否学到 signal, 而不是只判断 value loss 数值是否下降。

DataProto 字段

当前 v3 需要的字段:

<code>data.batch["advantages"]</code>	GiGPO policy advantage; keep unchanged
<code>data.batch["state_values"]</code>	old value prediction, shape [batch]
<code>data.batch["step_returns"]</code>	value target, shape [batch]
<code>data.batch["value_step_rewards"]</code>	reward used for value target diagnostics

当前不需要新增 `step_advantages` 进入 policy loss。只要 policy advantage 改了, 就不是当前 v3。

对照实验

第一轮只做 value-head 相关对照：

实验	设置	目的
GiGPO no-value-head	value head off	policy baseline
v3 value head detach=true	主线	value 学习且不干扰 policy
v3 value head detach=false	value loss 回传 backbone	复验干扰风险
v3 value coef	value_loss_coef=0.01/0.03/0.05	loss 权重敏感性
v3 value lambda	step_lam=0.90/1.00	target 方差敏感性

不要做的改动

除非用户明确要求新版本，不要在当前 v3 默认路径中加入：

- `algorithm.adv_estimator=step_ppo_v3;`
- `pure step advantage;`
- `action-level PPO ratio;`
- `policy_loss.loss_mode=action_level;`
- `separate critic;`
- value loss 默认更新 actor backbone。

Implementation Order

1. 保持 GiGPO value-aux trainer 路径。
2. 增加 v3 value-head run script。
3. 增加 value RMSE/MAE/EV/std diagnostics。
4. 编译 014-016 PDF 文档。
5. 提交脚本、文档、AGENTS 约定和指标代码。