

016: StepPPO-v3 设计 Review

2026-06-09

Review 结论

当前 StepPPO-v3 的设计应保持非常简单：它就是 GiGPO 训练上的 value head 实验。目标不是提出新的 advantage 或新的 PPO ratio，而是看 value head 能不能稳定学出来，并且确认加了这个 head 不影响 GiGPO 的训练。

因此，v3 的正确默认定义是：

```
StepPPO-v3 = GiGPO policy training + actor-side shared value head
```

主线不应再被描述成“先验证 value head，后面再做完整 v3”。当前这个 value-head-only 设定本身就是 v3。

必须坚持的边界

- GiGPO policy advantage 不变。
- GiGPO policy loss 路径不变。
- value head 使用和 StepPPO-v2 同一类 actor-side shared value head 思路。
- value head 学 step-level return/value target。
- 主线默认 detach_value_backbone=true，避免 value loss 干扰 actor backbone。
- success criterion 是 value 学得稳且 GiGPO 不退化。

当前脚本

主线脚本应是：

```
exps/run_webshop_step_ppo_v3_value_head_4gpu_paper_align_simple.sh
```

它应继续调用 GiGPO-v1 value-aux 路径，而不是切到一个新的 step_ppo_v3 estimator。

Review 关注点

1. value head 是否稳定

必须看：

```
actor/value_loss
actor/value_rmse
actor/value_mae
actor/value_explained_variance
actor/value_pred_std
actor/value_return_std
```

如果 value loss 看似下降，但 explained variance 长期小于等于 0，说明 value head 没有学到有用 signal。

2. 是否影响 GiGPO 训练

必须和 no-value-head GiGPO baseline 对比：

```
episode/valid_action_ratio
response_length/mean
response_length/clip_ratio
actor/pg_loss
actor/grad_norm
val/success_rate
val/webshop_task_score (not success_rate)
```

如果这些指标明显变差，哪怕 value head 指标变好，当前 v3 也不能算成功。

3. detach 对照

主线应是 detach=true。detach=false 只作为风险复验，用来确认 shared-backbone value regression 是否会干扰 policy。它不应该成为默认主线。

不要扩大 v3 范围

以下内容不要写进当前 v3 默认设计：

- `algorithm.adv_estimator=step_ppo_v3`;
- pure step advantage;
- action-level PPO ratio;
- sequence geometric ratio;
- separate critic;
- 复杂 reward 重写;
- 默认让 value loss 回传 actor backbone。

这些都可能是未来新版本或额外 ablation，但不是当前 v3。

通过标准

当前 v3 通过的标准很直接：

1. value head 的 RMSE/MAE 稳定，explained variance 出现正向 signal；
2. value prediction 不塌缩成常数，actor/value_pred_std 保持合理；
3. GiGPO 的 valid action、response length、clip ratio、validation score 不因为 value head 明显退化；
4. detach=true 明显比 detach=false 更不干扰 policy，或者至少不比 no-value-head baseline 差。

最终意见

当前设计应去掉所有不必要复杂度。v3 就是 value head；看它能不能学，且不影响 GiGPO。AGENTS 中也应强制记录这一点，避免后续 agent 又把 v3 扩展成 action-level PPO 或新的 advantage 算法。