

017: StepPPO-v3 Value Head 是否有效学习分析

2026-06-09

结论

我认为 value head 是有效学到了一部分东西的，尤其是 pred-target ranking / correlation。
但它还不是一个“标定很好”的 value function: raw value_loss 不稳定，actor 日志里的 value_explained_variance 很差。

更准确地说: value head 已经从近似常数预测，逐渐学成能跟随 target 排序和尺度的 predictor；
但 absolute calibration 仍然不够稳定。

使用的日志

主要依据如下两个文件:

```
logs/  
  webshop_gigpo_v1_value_aux_step_ppo_v3_value_head_detach_false_qwen25_15b_4gpu_paper_align_simple_20260609  
  .log  
logs/value_diagnostics/step_ppo_v3_value_head_detach_false_qwen2.5_1.5  
  b_4gpu_paper_align_full_e250/summary.jsonl
```

其中 console log 给出训练过程中 actor microbatch 侧聚合指标; summary.jsonl 给出每个 global step 的 batch-level value diagnostics, 包括 pre-update prediction、target、error、correlation、std 等。

关键证据

1. pred-target correlation 明显提升

Step Window	1-20	41-60	61-80	81-100	101-122
Correlation	0.075	0.288	0.437	0.641	0.738

这个趋势说明 value head 不是完全随机或只输出常数。它后期已经能较好地地区分哪些 step-level target 更高，哪些更低。

2. 归一化误差在下降

如果只看 raw RMSE，会被 target scale 增大误导。因此更合理的指标是：

$$\text{NRMSE} = \frac{\text{RMSE}(V_{\theta}(s_t), \hat{R}_t)}{\text{Std}(\hat{R}_t)}. \quad (1)$$

窗口均值如下：

Step Window	1-20	21-40	41-60	61-80	81-100	101-122
RMSE / target std	1.034	1.017	0.995	0.921	0.798	0.686
MAE / target std	0.336	0.578	0.824	0.815	0.626	0.478

这说明虽然 raw value loss 没有单调下降，但相对于 target 的尺度，value prediction 的误差是在变小的。

3. 预测方差开始接近 target 方差

早期 value head 基本输出近似常数，预测方差很小。后期 `pred_std/target_std` 明显上升：

Step Window	1-20	21-40	41-60	61-80	81-100	101-122
pred std / target std	0.096	0.033	0.102	0.366	0.665	0.795

这个结果说明 value head 从“压缩预测”逐步变成了能覆盖 target 动态范围的 predictor。

为什么 raw value loss 没下降

raw `value_loss` 从前期约 0.9 上升到后期 3-5，看起来像没学好。但 target 本身不是 stationary 的：policy 变好后，episode reward 和 return scale 明显变大。

例如 diagnostics 中 target std 从 1.224 增到 3.981。因此 absolute MSE 变大是预期内的，不应只看 raw loss。

当前更应该关注：

- normalized RMSE;
- pred-target correlation;
- prediction std / target std;
- full-batch value explained variance，而不是小 microbatch 上的 explained variance。

仍然存在的问题

actor 日志里的 `actor/value_explained_variance` 很差，后面甚至到 -20 左右。

这个指标是在较小 microbatch 上算的，target variance 很小时会极端不稳定；所以我更信 diagnostics 的 full-batch summary。但这也说明 value head 的 calibration 还不够稳，尤其是局部 batch 上可能偏差很大。

另外，bias 没有完全消失。后期窗口平均 bias 接近 -0.041，但单步仍然有明显波动。

Selected Step 证据

Step	Corr	NRMSE	Bias	Std Ratio	RMSE	Target Std
1	-0.042	1.120	-0.461	0.140	1.095	0.977
20	0.104	0.998	0.009	0.023	1.815	1.818
50	0.461	0.975	-0.560	0.094	3.265	3.349
80	0.623	0.795	-0.323	0.505	3.072	3.862
100	0.674	0.749	0.496	0.686	3.011	4.020
110	0.836	0.564	-0.235	0.721	2.279	4.041
120	0.809	0.588	0.028	0.790	2.435	4.140

后期 correlation 达到 0.8 左右, NRMSE 下降到 0.56–0.59, std ratio 接近 0.8。这是比较明确的有效学习信号。

判断

如果目标是“验证 value head 能不能学到 step-level return signal”：目前答案偏 **yes**。

如果目标是“这个 value 已经可以安全替代或影响 policy advantage”：目前还不够。

v3 作为 auxiliary value-head 实验是合理的；下一步建议把 normalized value metrics 写入主日志，例如：

```
actor/value_nrmse
actor/value_corr
actor/value_full_batch_ev
actor/value_std_ratio
actor/value_bias
```

否则只看 raw value_loss 会误导判断。

最终结论

value head 确实学到了 signal, 但主要体现在 correlation、normalized error 和 scale matching 上, 而不是 raw loss 单调下降。当前 value head 对 target 的排序能力已经明显增强; 但 calibration 和 explained variance 仍需改进。因此, v3 的 value-head-only 方向是有希望的, 但还不能把这个 value 直接当成稳定 critic 使用。