

018: StepPPO-v3 Value-Head-Only 完整实验分析

2026-06-10

摘要结论

这次 StepPPO-v3 完整跑到 **global step 250**。从 value diagnostics 看, value head 的学习信号非常明确: pred-target correlation、normalized RMSE、prediction scale matching、full-batch explained variance 和 sample-level ranking 都持续改善。因此, **v3 的核心问题 “actor-side shared value head 能不能学到 step-level return/value signal” 目前答案是 yes。**

但是, 这次完整 run 使用的是 `detach_value_backbone=False`。它允许 value loss 回传 actor backbone。结果表明 policy 没有崩, 但后期 actor 行为出现明显漂移: response length 和 response clip ratio 大幅升高, 导致 generation time 和 total step time 变慢, 并且 task score 相比 GiGPO baseline 有下降。因此, **这次 run 支持 “value head 可学习”, 但不支持 “detach=false 完全不影响 GiGPO”。**

1 StepPPO-v3 的实现原理

本节先把 v3 的代码设计讲清楚, 使后面的指标分析可以自包含地理解。

1.1 v3 的定位: value-head-only, 不改 GiGPO policy

当前分支中的 StepPPO-v3 不是一个新的 policy-gradient estimator, 也不是把 step-level value 直接接入 policy advantage 的算法。它的实验目标很窄:

- 保持 GiGPO 原本的 rollout、policy advantage、policy loss 和 PPO ratio 路径不变。
- 在 actor 侧额外加一个 shared value head, 用来预测 step-level value/return target。
- 检查两个问题: 第一, value head 能不能稳定学到 step-level target; 第二, 加入这个 auxiliary loss 后, 会不会损害 GiGPO 原本训练行为。

因此, 训练时 actor 的 policy loss 仍然由 GiGPO 的 advantage 决定。value head 的损失只是一个 auxiliary loss: 它不会在这次 v3 中替代 GiGPO advantage, 也不会直接改变 action-level PPO ratio。

1.2 value 是怎么得到的

每一个 WebShop episode 可以看成是一个多步交互轨迹。第 i 个 step 在生成 action 之前有一段 context, 包括任务、历史 observation、历史 action 和当前 observation。模型对这段 context 做 forward 后, 会得到每个 token 的 hidden state。v3 只选取一个 hidden state 作为 step-level 表示:

$$h_i = h_{\text{pre-action-last-context-token}} \quad (1)$$

直观上, h_i 是模型在“准备生成当前 step action 之前”对当前状态的表示。value head 只接收这个 selected hidden state, 而不是所有 token 的 hidden states:

$$v_i = f_{\phi}(h_i), \quad (2)$$

其中 f_ϕ 是一个很小的 MLP value head，输出 scalar prediction $v_i \in \mathbb{R}$ 。这个 scalar 被解释为当前 step 的 predicted step-level return/value。

1.3 value target 是什么

v3 使用 step-level return target，而不是 final episode reward 的直接 copy。记 step-level reward 为 r_i ，bootstrapped/GAE-style target 记为 y_i 。代码中该 target 对应 diagnostics 里的 `value_target_gae_return`。可以把它理解成当前 step 往后能获得多少 normalized/discounted return 的训练标签。

简化地说，target 的构造类似：

$$y_i \approx \sum_{k \geq i} \gamma^{k-i} \lambda^{k-i} r_k, \quad (3)$$

本次实验配置中使用 `step_gamma=0.95` 和 `step_lam=0.90`。实际实现还会结合 trajectory 内 step reward、valid action penalty 和 batch 组织方式，但核心含义就是：用未来 step-level return 监督 value head。

1.4 value loss 如何加入 actor update

value head 的基本优化目标是让 prediction v_i 接近 target y_i 。不考虑 clipping 时，最简单形式是 MSE：

$$\mathcal{L}_{\text{value}} = \frac{1}{N} \sum_{i=1}^N (v_i - y_i)^2. \quad (4)$$

代码里还保留了 PPO-style value clipping，对应配置 `cliprange_value=0.5`，用于限制单次 value update 的过大变化。总 actor-side loss 可以抽象成：

$$\mathcal{L}_{\text{actor}} = \mathcal{L}_{\text{GiGPO policy}} + c_v \mathcal{L}_{\text{value}} + \text{KL/entropy/penalty terms}, \quad (5)$$

本次 $c_v = 0.03$ 。

1.5 detach_value_backbone 的含义

`detach_value_backbone` 决定 value loss 是否回传到 actor backbone：

- 若 `detach_value_backbone=True`，value head 看到的是 detached hidden state。value loss 只更新 value head 参数，不更新 actor backbone。这个设置更适合验证“value head 自身能否从固定 actor representation 中读出 value signal”，也更安全，因为它较少干扰 GiGPO policy。
- 若 `detach_value_backbone=False`，value loss 会回传到产生 h_i 的 actor backbone。这个设置可能让 representation 更适合 value prediction，但也可能改变 policy 的 hidden representation，从而影响 GiGPO 的行为分布。

本次完整实验使用 `detach_value_backbone=False`。因此，本报告后面对 actor drift 的分析非常重要：如果后期 policy 行为变差或生成变长，不能排除 auxiliary value loss 对 backbone 的影响。

2 实验数据和对照设置

本次分析把 v3 的完整训练轨迹定义为：初始 run 的 step 1–100 加上 resume run 的 step 101–250。第一次 run 在 121/122 左右中断，但最后保存的 checkpoint 是 step 100；resume 从 step 100 checkpoint 继续，因此 step 101–121 应以 resume run 为准。

```
# v3 stage-1 log, use steps 1--100
logs/webshop_gigpo_v1_value_aux_step_ppo_v3_value_head_detach_false_qwen25_15b_4gpu_paper_align_simple_20260609_070507.log

# v3 resume log, use steps 101--250
logs/webshop_gigpo_v1_value_aux_step_ppo_v3_value_head_detach_false_qwen25_15b_4gpu_paper_align_simple_20260610_012702.log
```

```
# v3 diagnostics, use stage-1 1--100 and resume 101--250
logs/value_diagnostics/step_ppo_v3_value_head_detach_false_qwen2.5_1.5b_4gpu_paper_align_full_e250/
logs/value_diagnostics/step_ppo_v3_value_head_detach_false_qwen2.5_1.5b_4gpu_paper_align_full_e250_resume_20260610_012700/
```

GiGPO 对照采用已有三 seed 完整 baseline:

```
logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260530_114442.log
logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260531_004613.log
logs/webshop_gigpo_qwen25_15b_4gpu_paper_align_simple_20260531_123134.log
```

所有窗口统计均按 50 step 分段：1–50、51–100、101–150、151–200、201–250。value diagnostics 使用每 step 的 full-batch summary；sample-level ranking 使用每 step dump 的最多 512 条 sample rows。

3 Value learning 指标定义

为了判断 value head 是否“学到了”，不能只看 raw value loss。原因是 target y_i 本身是 non-stationary 的：policy 变好后 reward/return 的尺度会变大，MSE 可能因为 target scale 变大而上升。下面定义的指标更能区分“模型是否真正捕捉了 target 结构”。

3.1 Pred-target correlation

给定一个 batch 中的 prediction v_i 和 target y_i ，Pearson correlation 定义为：

$$\rho(v, y) = \frac{\sum_i (v_i - \bar{v})(y_i - \bar{y})}{\sqrt{\sum_i (v_i - \bar{v})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}. \quad (6)$$

它衡量 prediction 和 target 的线性相关程度。若 value head 只是输出常数，prediction variance 很小，correlation 会接近 0 或不稳定。若 value head 学会“哪些状态的 future return 更高，哪些更低”，correlation 应该上升。

Correlation 对 value learning 很重要，因为 value function 的第一步能力就是**排序/区分状态好坏**。即使 absolute calibration 暂时不准，只要 correlation 持续提升，就说明 representation 和 value head 已经捕捉到 return-related signal。

3.2 RMSE 和 NRMSE

RMSE 定义为：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (v_i - y_i)^2}. \quad (7)$$

但是 raw RMSE 会受 target 尺度影响。若 y_i 的 standard deviation 从 1 增到 4，即使模型相对误差变小，raw RMSE 也可能变大。因此我们使用 normalized RMSE：

$$\text{NRMSE} = \frac{\text{RMSE}}{\text{Std}(y)}. \quad (8)$$

NRMSE 的直觉是：prediction error 相对于 target 自身波动有多大。若 NRMSE 约等于 1，说明误差和 target 的自然波动同量级；若明显小于 1，说明 prediction 已经解释了 target 中相当一部分结构。NRMSE 下降比 raw loss 下降更能说明 value head 在 non-stationary RL 训练中学到了东西。

3.3 Prediction std / target std

这个指标定义为：

$$\text{StdRatio} = \frac{\text{Std}(v)}{\text{Std}(y)}. \quad (9)$$

它衡量 prediction 的动态范围是否接近 target。如果 value head 输出近似常数，则 $\text{Std}(v)$ 很小， StdRatio 接近 0。若 value head 开始覆盖 target 的高低变化， StdRatio 会接近 1。当然， StdRatio 接近 1 本身不保证正确，因为 prediction 可能有方差但方向错；所以它必须和 correlation 一起看。理想情况是：correlation 高，同时 StdRatio 接近 1。

3.4 Full-batch explained variance

这里使用 diagnostics 的 full-batch RMSE 和 target std 计算 implied explained variance：

$$\text{EV} = 1 - \frac{\text{MSE}}{\text{Var}(y)} = 1 - \text{NRMSE}^2. \quad (10)$$

EV 的意义是 prediction 解释了 target variance 的多少。EV=0 表示和只预测 target mean 差不多；EV>0 表示优于常数 baseline；EV 越接近 1 越好。actor console log 里的 `actor/value_explained_variance` 是 microbatch 上算的，容易受小 batch 和 target variance 波动影响，所以本报告更信任 diagnostics 的 full-batch EV。

3.5 Normalized bias

Bias 定义为 prediction error 的均值：

$$\text{Bias} = \frac{1}{N} \sum_i (v_i - y_i), \quad \text{NormBias} = \frac{\text{Bias}}{\text{Std}(y)}. \quad (11)$$

它衡量 value head 是否整体高估或低估。Correlation 高但 bias 很大，说明排序可能学到了，但 calibration 仍不准。因此 bias 是 calibration 的补充指标。

4 Value head 是否学到了？

结论是明确的：**学到了，而且越到后期越明显。**

Metric / Window	1-50	51-100	101-150	151-200	201-250
Pred-target corr	0.144	0.493	0.766	0.811	0.861
NRMSE	1.021	0.885	0.654	0.588	0.508
Pred std / target std	0.064	0.441	0.822	0.855	0.936
Full-batch EV	-0.043	0.205	0.559	0.644	0.723

这四行指标共同构成比较强的证据链：

- **Correlation 上升**说明 prediction 与 target 的方向越来越一致，value head 开始能区分高 return 和低 return step。
- **NRMSE 下降**说明误差相对 target 自身波动越来越小，不是仅仅因为 target scale 改变导致的假象。
- **StdRatio 接近 1**说明 value head 不再输出被压缩的近似常数，而是开始覆盖 target 的动态范围。
- **Full-batch EV 从负到正并持续上升**说明 prediction 从不如常数 baseline，变成能解释 target variance 的 predictor。

因此，虽然 raw `actor/value_loss` 不是单调下降，仍然可以判断 value head 在学习。特别是 201-250 窗口，corr=0.861、NRMSE=0.508、StdRatio=0.936、EV=0.723，这已经是比较明显的可学习信号。

Selected steps 也能看到同样趋势：

Step	Corr	NRMSE	Full EV	Std Ratio	Bias / Std
1	-0.042	1.120	-0.254	0.140	-0.472
50	0.461	0.975	0.049	0.094	-0.167
100	0.674	0.749	0.439	0.686	0.123
150	0.717	0.728	0.470	0.804	-0.192
200	0.933	0.369	0.864	0.888	0.073
225	0.955	0.302	0.909	0.950	-0.051
250	0.872	0.515	0.735	0.916	0.150

Step 250 比 step 225 稍有回落，但仍明显优于早期。这种单步波动在 RL 训练中正常，因为每个 batch 的 tasks、episode outcomes 和 target distribution 都不同。更可靠的是窗口均值趋势。

5 Sample-level ranking 的定义和意义

Batch-level correlation 可能掩盖一些问题：例如 prediction 在 batch 内整体相关，但在具体 sample 层面并不能稳定地区分好坏。为了进一步验证，我们使用 dumped rows 做 sample-level ranking analysis。

具体做法如下：

1. 收集一个窗口内所有 dumped samples，每个 sample 有 prediction v_i 和 target y_i 。
2. 按 prediction v_i 从低到高排序。
3. 将 samples 分成五个等量 quintiles：Q1 是 prediction 最低的 20%，Q5 是 prediction 最高的 20%。
4. 计算每个 quintile 的平均 target return。
5. 如果 value head 有用，那么 Q5 的平均 target 应该显著高于 Q1，并且 target 应随 quintile 大致单调上升。

这个指标检验的是 value head 是否能在 sample 层面对状态做排序。它比只看 MSE 更贴近 value function 在 RL 中的用途：value 需要告诉我们哪些状态/step 更有希望，哪些更差。

Window	Pearson	Spearman	NRMSE	Top-bottom target gap
1-50	0.381	0.760	0.936	2.454
51-100	0.520	0.553	0.857	5.415
101-150	0.780	0.823	0.630	8.433
151-200	0.814	0.858	0.584	8.734
201-250	0.873	0.909	0.492	9.112

这里 Pearson correlation 衡量线性相关；Spearman correlation 衡量 rank correlation，即 prediction 排名和 target 排名是否一致。Spearman 后期达到 0.909，说明排序能力非常强。Top-bottom target gap 从 2.454 增到 9.112，说明高 prediction quintile 对应的真实 target return 明显更高。

因此 sample-level ranking 的结论是：value head 不只是 batch summary 上“看起来相关”，它在 individual sample 层面也能把高 return step 和低 return step 分开。

6 为什么 raw value loss 会误导

在 supervised learning 中，loss 下降通常直接表示学得更好。但 RL 里的 value target 是 non-stationary 的：policy 变强后，episode reward、trajectory length、valid action ratio 和 return distribution 都会变化。若 target variance 变大，MSE/MAE 即使在相对意义上改善，也可能在绝对数值上不降反升。

因此，本实验里 raw actor/value_loss 的解释应当非常谨慎：

- 若 target std 上升, raw RMSE 上升不一定代表 value 学坏了。
- 若 prediction std 也跟随 target std 上升, 并且 correlation 上升, 说明模型正在学习 target 的结构。
- 若 NRMSE 下降、EV 上升, 则说明相对 target distribution 的误差确实在下降。

这也是为什么本报告把 corr、NRMSE、StdRatio、EV 和 sample-level ranking 作为主要判断依据, 而不是只看 console log 中的 raw value loss。

7 Actor 行为是否被影响

value head 的另一个关键问题是: 它是否影响了 GiGPO 原本训练。这里要区分 “policy 是否崩掉” 和 “policy 是否完全不受影响”。本次结果是: **没有崩, 但后期有明显 drift**。

Window	Metric	v3	GiGPO mean	Delta
1-50	success	0.156	0.155	+0.001
51-100	success	0.477	0.441	+0.036
101-150	success	0.647	0.623	+0.024
151-200	success	0.706	0.699	+0.007
201-250	success	0.717	0.736	-0.019
1-50	task score	0.476	0.456	+0.020
51-100	task score	0.741	0.720	+0.021
101-150	task score	0.789	0.812	-0.022
151-200	task score	0.838	0.855	-0.017
201-250	task score	0.822	0.871	-0.049
201-250	valid action ratio	0.947	0.997	-0.050
201-250	response clip ratio	0.426	0.0015	+0.425
201-250	response length mean	293.167	127.803	+165.364

这些 actor 指标的含义如下:

- **success rate**: episode 是否成功完成任务。它是最直观的最终指标, 但比较粗糙。
- **task score**: WebShop 的连续评分, 比 success 更细, 可以反映部分匹配质量。
- **valid action ratio**: 模型输出是否能被环境解析成合法 action。下降说明 action formatting 或策略稳定性变差。
- **response length / clip ratio**: 模型输出长度和是否触达 max response length。clip ratio 高说明模型经常生成到长度上限, 这通常是 actor 行为漂移或冗长推理的信号。

关键现象是 response length。前 150 step 基本可控, 但 151 之后 clip ratio 开始升高, 201-250 达到非常高的 0.426。这个变化比 success/task score 更值得重视, 因为它说明 actor 的输出分布发生了明显变化。虽然 final success 没有大幅下降, 但 task score、valid action ratio 和 runtime 都受到影响。

Validation 结果也支持这个更谨慎的判断:

Validation metric	v3 @250	GiGPO mean @250	Delta
Success rate	0.742	0.752	-0.010
Task score	0.843	0.885	-0.042

如果只看最后 6 个 validation checkpoint (225-250), v3 success 平均 0.750, GiGPO 平均 0.743, success 不差; 但 v3 task score 平均 0.837, GiGPO 平均 0.875, 仍低约 0.037。因此不能只看 success, 要同时看 task score、valid action ratio 和 response clipping。

8 训练时间和资源分析

value head 本身的 diagnostics dump 很轻，但这次总 runtime 后期明显变慢。主要原因不是每步 dump 文件，而是 actor 输出变长后 generation token 数增加。

Window	Metric	v3	GiGPO mean	Ratio
1-50	step time	164.0s	163.9s	1.00
51-100	step time	133.3s	148.3s	0.90
101-150	step time	150.1s	117.8s	1.27
151-200	step time	173.2s	104.2s	1.66
201-250	step time	189.9s	105.1s	1.81
201-250	generation time	165.3s	88.0s	1.88
201-250	actor update time	16.1s	11.3s	1.43
201-250	throughput	1742.1	2281.6	0.76

因此，“value head 会不会显著增加训练时间”需要拆开看：

- diagnostics dump 开销很小，每步大约几十毫秒量级。
- actor update 末段从 GiGPO 的 11.3s 增到 16.1s，说明 value head/backbone update 确实带来一些训练开销。
- 最大 runtime 问题来自 generation 变长：201-250 的 generation time 是 baseline 的 1.88 倍，这和 response clip ratio 大幅升高一致。

9 曲线总览




图 1: Value head 学习曲线。灰色虚线为 step 100 resume 边界。




图 2: v3 actor 行为与 GiGPO 三 seed baseline 对比。




图 3: v3 runtime/resource 与 GiGPO 三 seed baseline 对比。




图 4: 基于 dumped sample 的 value ranking/calibration 诊断。

10 对 v3 设计的判断

这次实验支持如下判断：

1. **selected hidden state 设计是可学习的**。只把 `pre_action_last_context_token` 的 hidden state 喂给 value head，并没有阻止 value 学习；后期 ranking、correlation 和 scale matching 都明显改善。
2. **step-level GAE return target 有有效信号**。如果 target 主要是噪声，corr 和 Spearman ranking 不应持续上升到 0.8-0.9 区间。
3. **detach=false 风险较大**。它让 value loss 直接回传 actor backbone。当前 run 说明这种设置可能诱发 response length drift，从而影响 GiGPO 的行为和成本。
4. **当前结果还不支持把 value 直接用于 policy advantage**。value head 已有不错 ranking，但 actor 行为已经受影响；在把 value 接入 advantage 前，需要先稳定 actor 行为。

11 建议的下一步

我建议下一轮只围绕“value head 可学习且不影响 GiGPO”继续做最小 ablation：

- 跑一个完整 `detach_value_backbone=True, value_loss_coef=0.03`，验证是否能保留 value learning，同时消除 response length drift。
- 如果 `detach=true` 学习明显变慢，再试 `detach=false` 但降低 `value_loss_coef`，例如 0.01 或 0.003。
- 把 diagnostics 中的 `value_nrmse`、`value_corr`、`value_std_ratio`、`value_full_batch_ev` 写入主日志，而不是只依赖 raw actor/value_loss。
- 把 `response_length/clip_ratio` 作为 v3 的 hard safety metric；如果超过 0.1，应优先分析 actor drift，而不是继续解释 value loss。

12 产物位置

本次新增的分析脚本、曲线和表格如下：

```
EXPS/visualization/plot_step_ppo_v3_complete_analysis.py
EXPS/figures/018_step_ppo_v3_value_learning_curves.png
EXPS/figures/018_step_ppo_v3_policy_vs_gigpo_curves.png
EXPS/figures/018_step_ppo_v3_runtime_resource_curves.png
EXPS/figures/018_step_ppo_v3_value_calibration_curves.png
EXPS/data/018_step_ppo_v3_complete_analysis_summary.txt
EXPS/data/018_step_ppo_v3_policy_window_summary.csv
EXPS/data/018_step_ppo_v3_runtime_window_summary.csv
EXPS/data/018_step_ppo_v3_validation_summary.csv
EXPS/data/018_step_ppo_v3_value_window_summary.csv
EXPS/data/018_step_ppo_v3_value_sample_ranking_summary.csv
EXPS/data/018_step_ppo_v3_value_selected_steps.csv
```

13 最终结论

v3 的核心问题“value head 能不能稳定学出 step-level value/return target”已经得到比较正面的答案：能学，而且后期已经学到很强的 ranking signal 和相当好的 normalized calibration。

但这次 `detach_value_backbone=False` run 暴露出另一个问题：value loss 回传 backbone 后，actor 行为并非完全保持 GiGPO baseline，后期 response length drift 很明显。所以 v3 当前最合理的定位仍

然是 auxiliary value-head 验证, 而不是更进一步的 policy-advantage 改造。下一步应该优先验证 detach=true 或更小 value loss coefficient, 目标是保留 value learning, 同时恢复 GiGPO 的 response length、valid action ratio、task score 和 runtime 行为。