

020: Signal Trustworthiness Analysis Experiments

日期: 2026-06-10

1. 问题

我们已经有一轮 StepPPO-v3 / value-head-only 训练结果: value head 的 sample-level ranking 逐渐变强, 但最终 WebShop validation 没有超过 GiGPO baseline, 后期还出现 valid action ratio 下降、response clip ratio 上升和 runtime 变慢。

这说明当前最值得做的不是马上继续叠新算法, 而是先回答一个更底层的问题:

哪些 step-level / trajectory-level 信号是真的可信, 哪些只是训练日志里看起来相关?

本文把下一阶段定义为分析类实验。目标是用已有日志、已有 rollout、已有训练模型 checkpoint, 在不先开启大规模新训练的前提下, 审计以下信号是否可靠:

- value head prediction;
- actor hidden-state similarity / 模型既视感;
- GiGPO hard group advantage;
- Soft-GiGPO semantic neighbor baseline;
- entropy / logprob uncertainty;
- environment transition signals;
- previous-policy / implicit step reward ratio;
- external PRM / judge / privileged teacher signals。

2. 参考论文与本地资料

已从 PaperIndex 复制 16 篇相关 PDF 到:

EXPS/papers/020_signal_trustworthiness/

该目录包含 manifest.json, 记录 citation key、title、PaperIndex 原路径和 arXiv URL。

2.1 直接相关论文

论文	对本项目的启发
POISE: Your Language Model is Its Own Critic	直接支持“actor internal state 可以作为 value / baseline 信号”的方向, 但要求 cross-rollout 设计来避免 biased policy gradient。
GiGPO	hard anchor-state grouping 是当前 Soft-GiGPO 的起点; 关键假设是 same state 下的 actions 可比较。
GAGPO	critic-free grouped value proxy + TD/GAE-style temporal advantage, 是 step advantage 可信性的重要参照。
Agentic RL with Implicit Step Rewards / iStar	用 previous policy snapshot 和 implicit PRM 构造 step reward, 提醒我们不要只依赖 initial reference。

论文	对本项目的启发
3SPO	historical success-rate state score 是一种离线可验证的 state-value surrogate。
T2-GRPO	把 turn-level environment-state transition reward 和 trajectory reward 分开标准化，适合分析环境转移信号。
PBSD	用 privileged answer-conditioned teacher 分解 Bayesian evidence，适合做“失败轨迹中哪些 step 其实有价值”的对照。
SPPO	反过来提醒我们：长 horizon 下不一定要强行 token/step credit，sequence-level scalar value 可能更稳。
RWML	用 textual world model / next-state reward 评估 agent action 后果，适合分析 transition signal。
WebArbiter	Web agent PRM 应输出 reasoning-first verdict，而不是只给弱 scalar。
ToolPRMBench	step-level tool/action reward 需要成对比较和多模型验证，不能只看最终结果。
Uncertainty Quantification in LLM Agents	agent UQ 不能照搬单轮 QA，需要跟随 interaction history、state、tool result 传播。
DenoiseFlow	把 agent workflow 当作 noisy MDP，分析 uncertainty propagation 和 root-cause localization。
STAPO	rare spurious tokens 可继承 positive advantage，提醒我们要查 reward 信号是否被格式/长度/罕见 token 污染。
PRPO	process reward 与 outcome reward 必须对齐，否则 dense signal 可能强化错误中间行为。
Claw-R1	step-level data middleware 说明信号审计需要先把 step 数据结构化。

2.2 当前本地证据

已有结果来自：

EXPS/data/018_step_ppo_v3_complete_analysis_summary.txt

logs/value_diagnostics/step_ppo_v3_value_head_detach_false_qwen2.5_1.5b_4gpu_paper_align_full_e250/
logs/value_diagnostics/step_ppo_v3_value_head_detach_false_qwen2.5_1.5b_4gpu_paper_align_full_e250_res

关键观察：

- value pred-target correlation 后期很强，201-250 窗口 sample-level pearson=0.873、spearman=0.909。
- final validation 没有提升：val/success_rate 为 0.742，GiGPO mean 为 0.752；val/webshop_task_score 为 0.843，GiGPO mean 为 0.885。
- value signal 变强时，policy 行为不一定更好：后期 valid action ratio 下降，response clip ratio 从 GiGPO 的约 0.002 升到 0.426。

初步结论：

value head 当前可作为 **ranking / diagnostic signal**，但还不能直接视为可训练 **policy advantage**。

3. 可信信号的判据

一个信号要进入 **policy update**，至少需要通过以下审计。否则只能作为诊断或 **reranking** 辅助。

3.1 Predictive validity

信号必须预测未来结果，而不是只解释当前格式。

要测：

- 与 **episode success / task score** 的 **Pearson**、**Spearman**；
- 与 **discounted future return** 的相关性；
- **top-k vs bottom-k lift**；
- **sign accuracy**: $\text{sign}(\text{signal}_i - \text{signal}_j)$ 是否预测同组未来 **return** 排序。

3.2 Locality

信号必须能回答“当前 **step/action** 是否好”，而不是只复述整条 **trajectory** 已经成功。

要测：

- 同一 **uid** 内、相近 **step_idx** 内的 **pairwise ranking**；
- **same anchor / soft-neighbor** 内的 **action ranking**；
- 去掉最终 **reward** 泄漏后的 **early-step prediction**。

3.3 Calibration

信号数值大小必须有意义。**ranking** 强但 **calibration** 弱时，只能用来排序，不能直接作为 **value target** 或 **dense reward**。

要测：

- **bin calibration curve**；
- **ECE / NLL / Brier**；
- **predicted value std** 与 **target std** 的比例；
- **per-step-index calibration**。

3.4 Stability

信号不能只在某个 **checkpoint**、某个 **seed**、某个训练阶段成立。

要测：

- **early / middle / late checkpoints**；
- **train task vs held-out validation task**；

- GiGPO baseline checkpoint vs StepPPO-v3 checkpoint;
- text embedding vs actor hidden state vs frozen actor hidden state。

3.5 Non-leakage

信号不能偷偷看到自己要预测的 reward。

要测：

- leave-one-out baseline;
- 不用同一 sample 的 future reward 构造自己的 baseline;
- 对 value/PRM 训练集和评估集按 uid 切分;
- 对 length、format、invalid action 做 partial correlation。

3.6 Intervention safety

离线相关性不等于在线有效。信号进入训练前，需要先做低风险干预。

推荐顺序：

1. offline ranking;
2. best-of-k reranking;
3. rollout filtering / early stop;
4. small 2GPU smoke;
5. full 4GPU training。

4. 实验 A: Value Head Reliability Audit

4.1 问题

value head 是否真的学到了 step-level return? 它能否从 diagnostic signal 升级为 advantage / critic?

4.2 数据

优先使用已有 JSONL:

```
logs/value_diagnostics/*/step_*.jsonl
logs/value_diagnostics/*/summary.jsonl
```

如果外部 checkpoint 可恢复，再补一次 held-out rollout forward probe。

4.3 指标

- `corr(value_pred, value_target)` by step window;
- `spearman(value_pred, value_target)` by uid;
- `top_decile_return - bottom_decile_return`;
- calibration bin: predicted value 分桶后的 true return;

- residual by `step_idx`;
- residual by response length / valid action / anchor group size;
- value error 与后续 policy regression 的相关性。

4.4 判定

可信：

- held-out uid 上 Spearman 稳定为正；
- top-bottom lift 稳定；
- calibration 不随 `step_idx` 明显翻转；
- partial correlation 控制 response length / valid action 后仍存在。

不可信：

- 只在训练 batch 内相关；
- 主要预测 response length、format 或 invalid action；
- 高 value 区间对应更高 clip ratio 或更差 valid action；
- detach=false 时 value 变好但 policy 变坏。

4.5 当前预判

已有证据支持“value head 有 ranking signal”，但不支持“直接作为 actor shared critic”。下一步应重点测 held-out correlation 和 partial correlation。

5. 实验 B: Actor Hidden-State Deja-vu / Semantic Similarity

5.1 问题

用户提出的核心问题是：actor 自己是否能感觉到当前 state 和之前某个 state 很接近？

这可以转化为：

给定 pre-action context 的 hidden representation $\mathbf{z}_i$ ，它的 nearest neighbors 是否真的是同一决策处境？这些 neighbors 的 future return 是否能构成可信 baseline？

5.2 表示选择

先比较四种表示：

1. `anchor_obs` text embedding；
2. current actor `pre_action_last_context_token` hidden state；
3. frozen initial/SFT actor hidden state；
4. frozen trained checkpoint hidden state。

如果 checkpoint 暂时不在当前 repo，可先用 text embedding 做 pipeline 验证，再等模型路径可用后切 actor-hidden 版。

5.3 指标

- top-k neighbor 的 same uid / same stage / same action-space precision;
- hard group singleton 被 soft neighbor 扩展后的比例;
- effective neighbor count: $1 / \sum_j w_{ij}^2$;
- neighbor return variance;
- similarity 与 $\text{abs}(R_i - R_j)$ 的相关性, 理想上越相似 return gap 越小;
- soft advantage 与 hard advantage 的 correlation / sign flip ratio;
- 人工抽样检查 top-5 neighbors。

5.4 判定

可信:

- top-k neighbors 人工看是同一任务阶段;
- similarity 越高, future return gap 越小;
- soft baseline 降低 singleton, 又不过度平滑;
- actor-hidden 比 text embedding 更能预测 action success。

不可信:

- neighbor 主要按表面文本、商品词、长度聚类;
- 跨阶段误匹配严重;
- similarity 高但 return gap 大;
- soft advantage 大量翻转 hard advantage 且无法解释。

6. 实验 C: Hard GiGPO Group vs Soft-GiGPO Group

6.1 问题

GiGPO 的 hard anchor grouping 是否真的提供可靠 step advantage? Soft-GiGPO 是否只是制造更多 baseline, 还是能提高信号质量?

6.2 离线计算

对同一批 rollout 计算:

- hard group return mean/std;
- hard advantage;
- soft top-k baseline;
- soft weighted std;
- fallback ratio;
- singleton ratio;
- hard-soft advantage correlation;
- sign flip ratio;
- advantage outlier rate。

6.3 Ablation

```
encoder: text_embedding / actor_hidden / frozen_actor
scope: same_uid only
top_k: 2 / 4 / 8 / 16
temperature: 0.03 / 0.07 / 0.10 / 0.20
fallback: hard / uid_mean / zero
```

6.4 判定

Soft-GiGPO 可进入训练的最低标准:

- `fallback_ratio` 不高于 hard singleton ratio;
- `effective_neighbors` 不塌缩到 1, 也不接近整个 uid group;
- soft advantage 对 held-out return 的 ranking 不低于 hard advantage;
- 人工检查 top-k neighbor 没有系统性错误;
- soft advantage outlier 少于 hard advantage。

7. 实验 D: Entropy / Logprob Uncertainty

7.1 问题

entropy、logprob、margin 是否能作为“当前 action 风险”的信号?

这个实验对应 Agent UQ 和 DenoiseFlow 的问题: agent 的不确定性是否沿 interaction history 累积, 并能定位错误源?

7.2 特征

- sequence mean entropy;
- first action-token entropy;
- action verb token entropy;
- mean old logprob;
- response length;
- top token margin, 如果可 dump logits;
- entropy delta across steps。

7.3 标签

- invalid action;
- next observation 是否异常或不变;
- episode failure;
- future discounted return;
- value residual;
- high clip-ratio sample。

7.4 指标

- AUROC / AUPRC for invalid action and failure;
- ECE for failure probability;
- entropy-by-step trend;
- uncertainty propagation: early high entropy 是否预测后面失败;
- root-cause localization: 失败轨迹里 entropy spike 是否出现在关键错误 step 前后。

7.5 判定

如果 entropy 只预测 response length 或 decoding randomness, 它只能做 diagnostics。如果它能稳定提前预测 invalid action / bad transition, 则可以用于 adaptive rollout、branching 或 early stop。

8. 实验 E: Environment Transition Signals

8.1 问题

环境自身给出的状态变化是否比模型内部信号更可信?

T2-GRPO 和 RWML 都提示: step signal 可以来自 environment transition, 而不是只来自 LLM judge 或 value model。

8.2 WebShop 候选信号

- `is_action_valid`;
- observation 是否变化;
- search page / detail page / item page stage;
- price / option / buy-button 是否出现;
- task query 与 observation 的 lexical/semantic overlap;
- repeated action / loop count;
- immediate reward delta;
- distance-to-purchase heuristic。

8.3 指标

- 单个 transition feature 对 final success 的 predictive power;
- 与 value head prediction 的互补性;
- 与 hard/soft advantage 的一致性;
- failed trajectories 中是否能定位首个不可恢复错误。

8.4 判定

这类信号如果稳定, 应优先作为 low-risk shaping / filtering feature, 因为它们比 hidden-state value 更可解释、更容易 debug。

9. 实验 F: Previous-Policy / Implicit Step Reward

9.1 问题

SIRPO/iStar 类思路强调 previous policy snapshot, 而不是固定 initial reference。我们可以测:

当前 policy 相对 few-step previous policy 的 logprob ratio 是否能反映行为质量变化?

9.2 需要的数据

- current checkpoint;
- previous checkpoint, 例如每 25 或 50 steps;
- same rollout batch 上的 action logprob;
- final outcome / future return。

9.3 候选信号

```
delta_logp_prev = log pi_t(a | s) - log pi_{t-k}(a | s)
delta_logp_ref = log pi_t(a | s) - log pi_0(a | s)
implicit_step_reward = delta_logp_prev - baseline(uid or neighbor)
```

9.4 审计

- `delta_logp_prev` 是否预测 future return;
- 它是否只是 reward model / format reward;
- few-step previous 比 initial reference 是否更稳定;
- 正 delta 的 actions 是否更容易 invalid 或过长;
- 与 value prediction / soft-neighbor advantage 是否互补。

9.5 判定

如果 few-step previous ratio 比 initial ref 更能预测 held-out success, 并且不被长度/格式污染, 它可以作为 SIRPO-style step reward 候选。否则只能作为 drift detector。

10. 实验 G: External PRM / Judge / Privileged Teacher

10.1 问题

外部 PRM 或 judge 是否能给 WebShop step 更可信的局部判断?

WebArbiter 和 ToolPRMBench 的共同提醒是: PRM 不能只给 scalar, 最好要有 pairwise action comparison、structured reason 和 verifier-style 标签。

10.2 低成本做法

先不训练 PRM，构造 offline pairwise set:

(history, observation, action_good, action_bad, task)

来源:

- same anchor / same soft neighbor 下 final return 高低不同的 action pair;
- success trajectory 与 failure trajectory 的 aligned step pair;
- invalid action vs valid action;
- human-checkable WebShop state/action pair。

10.3 输出

每个 pair 让 judge 输出:

- 哪个 action 更接近任务完成;
- 当前 state 属于哪个 stage;
- action 的局部风险;
- verdict reason;
- confidence。

10.4 审计

- judge verdict 与 future return pairwise accuracy;
- judge confidence calibration;
- judge 是否偏好格式正确但任务错误的 action;
- judge reason 是否能定位错误类型;
- 与 value / hidden similarity / environment features 的互补性。

10.5 判定

如果 judge 只在显然 invalid action 上有效，则不值得进入训练；如果它能区分同一页面下两个 plausible actions 的长期差异，则可以作为 PRM distillation 或 reranking 数据源。

11. 实验 H: Small Intervention Before Training

任何信号进入 policy gradient 前，都先做小干预。

11.1 Best-of-k reranking

在同一 prompt/task 上采样 k 条 trajectory，用候选信号选择 best trajectory 或 best next action。比较:

- selected trajectory success;
- oracle best success;
- random selected success;

- signal selected vs value selected vs entropy selected。

11.2 Rollout filtering

过滤高风险 step 或 trajectory，仅用于构造 SFT / DPO / correction 数据，不更新 RL objective。比较过滤后数据质量。

11.3 Early stop / adaptive rollout

如果信号能提前预测失败，测试提前终止或分支探索是否节省 rollout budget。

11.4 2GPU smoke

只有当离线和 reranking 都通过，才把信号接入 policy update。smoke 标准不是提高最终分数，而是：

- valid action ratio 不掉；
- response clip ratio 不爆；
- advantage std 不极端；
- validation 不出现快速 collapse。

12. 执行顺序

Stage 0: 数据整理

输出目录建议：

EXPS/analysis/020_signal_trustworthiness/

整理：

- 训练日志；
- value diagnostics JSONL；
- rollout step table；
- optional checkpoint path；
- selected paper manifest。

Stage 1: 不需要 checkpoint 的审计

先用已有日志和 JSONL 完成：

1. value head reliability audit；
2. entropy/logprob basic audit，如果日志里已有；
3. valid action / response length / clip ratio 与 value residual 的关系；
4. existing hard group signal，如果 diagnostics 中已有 group 字段。

Stage 2: 需要 checkpoint 的 forward probe

如果训练好的模型 checkpoint 可用，补：

- 1. actor hidden-state extraction;
- 2. current vs previous checkpoint logprob ratio;
- 3. hidden neighbor retrieval;
- 4. held-out rollout value prediction。

Stage 3: Soft-GiGPO offline matching

在同一批 rollout 上比较：

- hard anchor group;
- text embedding soft group;
- actor hidden soft group;
- frozen actor soft group。

Stage 4: 外部 PRM / Judge pairwise audit

构造 200-500 个 pairwise state/action case，先测 judge 是否有局部辨别力。

Stage 5: 小干预

只把通过审计的信号用于 best-of-k reranking、rollout filtering 或 2GPU smoke。

13. 预期结论格式

每个信号最后给一个 verdict：

Signal:
Evidence:
Failure modes:
Trust level: diagnostic / reranking / filtering / policy-gradient-ready
Next action:

初始预判如下：

信号	当前信任等级	原因
value head prediction	diagnostic / ranking	已有强 Spearman，但 policy 未收益，calibration 和干扰风险未过关。
hard same-anchor GiGPO advantage	filtering / weak policy signal	exact same state 时语义最干净，但 group 稀疏。
actor hidden-state similarity	unknown	直觉强，但必须证明 neighbor 真是同一决策处境。

信号	当前信任等级	原因
text embedding similarity	diagnostic	可快速验证 pipeline，但可能只抓表面文本。
entropy / uncertainty	diagnostic	可能预测 invalid/failure，也可能只是长度或 decoding 噪声。
env transition features	filtering candidate	可解释，风险低，适合先做 shaping/filtering。
previous-policy ratio	unknown	需要 checkpoint logprob，对比 initial ref 才能判断是否更好。
external PRM / judge	reranking candidate	需要 pairwise audit 和 calibration，不能直接信 scalar。

14. 具体下一步

1. 写 `collect_020_signal_table.py`: 把 value diagnostics、training logs、rollout metadata 合成 step-level parquet/csv。
2. 写 `analyze_020_value_signal.py`: 输出 value reliability report。
3. 若 checkpoint 可用，写 `dump_020_actor_state_probe.py`: dump selected hidden state、entropy、logprob。
4. 写 `analyze_020_soft_neighbors.py`: 比较 hard group 与 soft neighbor 的 quality。
5. 抽样 100 个 neighbor pair 和 100 个 high/low value pair，做人眼检查。
6. 再决定 Soft-GiGPO 是用 text embedding、actor hidden state，还是先只做 env-feature baseline。

15. 风险

- packaged repo 当前没有实际 `checkpoints/` 目录；checkpoint forward probe 依赖外部路径。
- 现有 v3 脚本和 AGENTS 约定存在 `detach_value_backbone=false` 与 safe default `true` 的不一致；做信号判断时要明确当前结果来自 `detach=false`。
- 如果只在训练 batch 上做分析，会高估信号可信度。
- 如果不控制 response length、valid action、step index，很多信号会被格式因素污染。
- 如果直接把 soft similarity 接入 policy update，错误 neighbor 会把 bias 放大成训练崩溃。