

021: Soft-GiGPO State Matching 的理论路线

日期: 2026-06-10

1. 收敛后的问题

本文只讨论一个问题:

GiGPO 依赖 exact same state / anchor observation 才能构造 step group; 如果 WebShop/agent 任务中很少出现完全一致 state, 我们能否从 RL 理论或 LLM 表示角度, 把 same-state 放宽成 soft state matching?

这不是泛化地讨论所有 reward signal, 也不是重新设计 StepPPO。目标是明确 Soft-GiGPO 的合理路线。

2. GiGPO 的核心假设

GiGPO 的 step-level comparison 隐含了一个条件:

rollout step	state	return	action / response
--------------	-------	--------	-------------------

因此, 同一 state 下可以用 group 内平均 return 作为 baseline:

$$A_i^{hard} = R_i - \frac{1}{|G_i|} \sum_{j \in G_i} R_j.$$

这个估计在 exact same state 下比较自然; 但在 WebShop 里, **anchor_obs** 的 exact match 有两个问题:

1. 太严格: 页面文本轻微变化、商品排序变化、历史上下文变化都会破坏 exact match。
2. 太表面: 文本相同也不一定代表 agent 的历史、约束、任务进展完全相同。

所以真正的问题不是“怎么找文本相似 state”, 而是:

什么条件下两个 histories 可以被当成可比较的 decision state?

3. RL 理论给出的放松方式

3.1 从 state equality 到 value-equivalence

设 agent 真实可决策状态是 s , 当前 action 后的 discounted return 为 $Q^\pi(s, a)$, baseline 应是 $V^\pi(s)$ 。如果我们用一组近邻 s_j 的 return 做 soft baseline:

$$b_i^{soft} = \sum_j w_{ij} R_j, \quad A_i^{soft} = R_i - b_i^{soft}.$$

理想 advantage 是:

$$A_i^\pi = Q^\pi(s_i, a_i) - V^\pi(s_i).$$

soft baseline 的偏差大致来自：

$$\text{Bias}_i \approx V^\pi(s_i) - \sum_j w_{ij} V^\pi(s_j).$$

因此 soft matching 成立的核心条件是：

$$\sum_j w_{ij} |V^\pi(s_i) - V^\pi(s_j)| \text{ small.}$$

也就是说，**soft group 不需要 state 完全相同，但必须近似 value-equivalent**。如果 neighbor 的 value 差异小，则 soft baseline 的 bias 可控；如果 neighbor 只是文本相似但 value 差异大，soft advantage 会系统性偏。

这给了一个很清楚的审计目标：所有 soft matching 方法都要证明它选出的 neighbor 有小的 future-return / value gap。

3.2 Bisimulation：更强的“行为等价”

MDP 中更强的等价是 bisimulation：两个 state 在所有 action 下有相近 immediate reward，并且转移到相近 future states。bisimulation metric 把 exact equivalence 放宽为连续距离：

$$d(s, s') \approx \max_a (|r(s, a) - r(s', a)| + \gamma W_d(P(\cdot|s, a), P(\cdot|s', a))).$$

如果 $d(s, s')$ 小，则两者在长期行为上相似，value difference 也可被界定。

对 Soft-GiGPO 的启发：

- 不应该只比较 observation 文本。
- 应该比较 reward、action availability、next observation / transition pattern、future return。
- 如果我们没有环境模型，就用可观测 proxy 近似这些项。

这说明 raw hidden cosine 不是理论终点；它只是一个可能的 proxy。更合理的 soft distance 应该接近：

decision distance = reward/transition/action/value/policy-prediction distance

3.3 State abstraction：same state 可以变成 abstract state

state abstraction 理论关心什么时候可以把多个 ground states 聚成一个 abstract state。常见的抽象条件包括：

- model-equivalence: reward 和 transition 相同；
- Q-equivalence: optimal/action value 相同；
- policy-equivalence: 当前 policy 下行为和 value 相近。

GiGPO 的 exact anchor group 可以看成最保守的 abstraction。Soft-GiGPO 可以看成近似 abstraction：

$$\phi(h_i) \approx \phi(h_j) \Rightarrow h_i, h_j \text{ 可比较.}$$

这里更准确地应该写 history h ，而不是 observation o ，因为 multi-turn agent 的有效状态是完整交互历史或 belief state。

3.4 Successor representation: 比较“未来会到哪里”

Successor Representation (SR) 把 state 表示为未来 occupancy:

$$\psi(s) = \mathbb{E} \left[\sum_{t \geq 0} \gamma^t \mathbf{1}[s_t] \mid s_0 = s \right].$$

如果两个 state 的 successor representation 相近，它们未来会访问的状态分布相近，因此对一大类 reward function 的 value 也相近。

对 WebShop 来说，SR 的可操作近似是：

- 两个 state 是否处在相近页面阶段；
- 下一步会不会进入相似页面；
- 是否都有同类可执行 action；
- 是否都接近 purchase / failure / loop；
- 未来 success probability 是否接近。

所以 Soft-GiGPO 最好的理论口径不是“语义相似”，而是：

predictive future similarity。

3.5 POMDP / Predictive State: agent 的 state 是 history

WebShop 对 LLM agent 更像 POMDP：单个 observation 不一定包含全部任务进展，完整 trace 才决定下一步。Predictive State Representation (PSR) 的观点是：state 可以表示为对未来 action-observation tests 的预测。

这正好解释用户的问题：**agent 行为依赖 trace，而不是单个 step observation。**

因此 Soft-GiGPO 不应在 anchor_obs 上做相似度，而应在：

`h_t = task + previous observations + previous actions + current observation`

这个 pre-action history 上做相似度。更进一步，相似度应比较两个 histories 对未来的预测，而不是当前表面文本。

4. LLM 角度：hidden state 能不能作为 soft state?

Transformer 的 pre-action hidden state 是对完整上下文的压缩；由于 attention，它可以依赖整个 trace。但训练目标主要是 next-token prediction，不保证它天然保留 reward-relevant state。

所以结论要分两层：

1. 可以用 actor 内部表示作为候选 soft state representation，因为它确实是 policy 做决策时使用的内部状态。

2. 不能直接相信 **raw hidden cosine**，因为 hidden 相似不必然等价于 value 相似、transition 相似或 action 可比。

比 raw hidden cosine 更稳的是比较 actor 诱导出来的预测对象：

```
pi_theta(a | h) over executable/candidate actions
V_theta(h) or return probe
predicted next observation / stage
hidden projection trained to predict future-return neighborhood
```

换句话说，LLM theory 支持的不是“最后一个 token hidden state 本身神奇地代表 state”，而是：

actor hidden state 可以被用来产生 predictive decision fingerprints。

5. Soft-GiGPO 的理论目标

Soft-GiGPO 应该把 hard same-state 改成以下条件：

$$h_i \sim h_j \quad \text{if} \quad D_{decision}(h_i, h_j) \leq \epsilon.$$

其中 $D_{decision}$ 不是单一文本距离，而是近似 value/bisimulation/predictive-state 距离：

$$D_{decision} = \alpha D_{stage} + \beta D_{action_mask} + \chi D_{\pi} + \delta D_{value} + \eta D_{transition}.$$

每一项的含义：

- D_{stage} ：是否同处搜索页、详情页、选项页、购买页、失败/循环状态。
- D_{action_mask} ：可执行动作集合是否相近。
- D_{π} ：actor 在候选 action 上的分布是否相近。
- D_{value} ：value / future-return probe 是否相近。
- $D_{transition}$ ：执行候选 action 后的 next-observation / stage prediction 是否相近。

第一版不需要全部实现，但这个公式明确了路线：**soft matching 要逼近 decision equivalence，而不是 plain semantic similarity。**

6. 推荐路线

6.1 第一优先级：Hard + Soft Backoff

不要第一版就完全替代 hard GiGPO。推荐：

1. 如果 hard group size 足够，继续用 hard group。
2. 如果 hard group 是 singleton 或 group size 太小，启用 soft backoff。
3. soft backoff 只在同一个 uid 内找 neighbors。
4. soft neighbors 必须先通过 stage/action-mask 过滤。
5. 再用 actor predictive distance 或 representation distance 排 top-k。

形式:

$$A_i = \begin{cases} A_i^{hard}, & |G_i^{hard}| \geq m \\ A_i^{soft}, & |G_i^{hard}| < m \text{ and confidence high} \\ 0 \text{ or episode-only,} & otherwise. \end{cases}$$

这个版本最稳，因为它不破坏 GiGPO 已经可靠的 exact-state signal，只补 exact match 缺失处。

6.2 第二优先级: Actor Predictive Distribution Matching

相比 hidden cosine，更推荐先比较 actor 在候选 action 上的分布。

对每个 history h_i ，构造候选 action set:

```
C_i = actions sampled in same uid
      + valid action templates
      + actions observed in nearby steps
```

计算:

$$p_i(a) = \pi_\theta(a|h_i), \quad a \in C_i.$$

然后用 JS/KL 距离:

$$D_\pi(h_i, h_j) = JS(p_i, p_j).$$

优点:

- 直接比较 actor 自己认为“现在能做什么”。
- 比 raw hidden cosine 更贴近 decision state。
- 不需要训练新模型。
- 可用 frozen actor，减少 non-stationarity。

缺点:

- 如果 actor 本身错误或过度自信，两个错误状态也可能被认为相似。
- 需要 action candidate normalization。

因此必须和 stage/action-mask 一起用。

6.3 第三优先级: Predictive / SR-style Matching

如果有额外工程预算，可以训练轻量 probe:

```
z(h) -> future return bucket
z(h) -> next stage
z(h) -> success probability
z(h) -> loop / invalid risk
```

然后用 probe 的中间表示或输出分布做 matching。这更接近 SR / PSR 的理论路线, 因为它显式预测 future。

但它比 actor distribution route 风险更高:

- probe 可能泄漏训练 reward;
- probe 可能只学到长度/格式;
- probe 需要 held-out uid 验证。

所以它适合作为第二阶段, 不适合第一版直接进 policy update。

6.4 第四优先级: Raw Hidden Cosine

raw hidden cosine 可以保留为 ablation, 但不应作为主路线。

如果要用, 也建议:

- 用 frozen checkpoint hidden;
- 加 projection layer, 不直接用原 hidden;
- whitening / normalize;
- 只在 same uid + same stage/action-mask 后使用;
- 用 offline neighbor audit 证明 value gap 小。

6.5 暂不推荐: 跨 uid matching

不同 WebShop task 目标不同, 跨 uid 即使 observation 很像, reward 语义也可能相反。第一版必须 same uid。跨 uid 只有在引入 task-goal-conditioned representation 后再考虑。

7. Soft Baseline 计算

同一 uid 内, 过滤候选 neighbors:

$$\mathcal{N}_i = \{j : u_j = u_i, j \neq i, D_{stage/action}(h_i, h_j) \leq \epsilon\}.$$

再计算 soft weight:

$$w_{ij} = \frac{\exp(-D_{decision}(h_i, h_j)/\tau)}{\sum_{k \in \mathcal{N}_i} \exp(-D_{decision}(h_i, h_k)/\tau)}.$$

soft baseline:

$$b_i^{soft} = \sum_{j \in \mathcal{N}_i} w_{ij} R_j.$$

soft advantage:

$$A_i^{soft} = R_i - b_i^{soft}.$$

可选标准化:

$$\hat{A}_i^{soft} = \frac{R_i - b_i^{soft}}{\sqrt{\sum_j w_{ij}(R_j - b_i^{soft})^2 + \epsilon}}.$$

必须使用 leave-one-out, 避免自己的 return 进入自己的 baseline。

8. Confidence Gate

Soft-GiGPO 的关键是不要在不确定时硬用 soft signal。建议加 confidence gate:

```
min_neighbors >= 2
effective_neighbors in [2, 8]
top1_distance < threshold
neighbor_return_std not too high
stage/action_mask match is true
soft_baseline not dominated by one neighbor
```

effective neighbors:

$$N_{eff} = \frac{1}{\sum_j w_{ij}^2}.$$

如果 gate 不通过:

```
fallback = hard advantage if available
           or episode-level GiGPO advantage
           or zero step advantage
```

9. 离线验证必须先做

Soft route 是否成立, 先不看训练分数, 而看四类理论审计。

9.1 Value-gap audit

检查 selected neighbors 是否满足:

$$|R_i - R_j| \text{ small or rank-consistent.}$$

更具体:

- similarity 越高, future return gap 是否越小;
- top-k neighbor return variance 是否低于 uid random neighbor;
- soft baseline error 是否低于 uid mean baseline;
- soft advantage 对 future return ranking 是否优于 hard singleton/uid mean。

9.2 Decision audit

人工或规则检查 top-k neighbors:

- 是否同一 WebShop stage;
- 是否有相近 action space;
- 是否任务目标仍一致;
- 是否 action 的局部语义可比较。

9.3 Bias audit

估计:

$$\widehat{Bias}_i = R_i^{future} - b_i^{soft}$$

或用 value probe 估:

$$\widehat{Bias}_i = V(h_i) - \sum_j w_{ij} V(h_j).$$

如果 bias 比 hard/uid baseline 更大, soft matching 不应进入训练。

9.4 Sign audit

policy update 关心 sign。检查:

sign(A_soft) vs sign(future-return advantage)

sign(A_soft) vs sign(A_hard) on non-singleton hard groups

如果 sign flip 很多, 而且无法解释, soft route 不可信。

10. 第一版配置建议

algorithm:

adv_estimator: gigpo

gigpo:

step_advantage_w: 1.0

soft_matching:

enable: true

mode: hard_backoff

scope: same_uid

min_hard_group_size: 2

prefilter:

same_stage: true

compatible_action_mask: true

encoder: actor_action_distribution


```

actor_snapshot: frozen_current_or_previous
distance: js_divergence
top_k: 8
temperature: 0.1
min_neighbors: 2
effective_neighbors_min: 2
effective_neighbors_max: 8
leave_one_out: true
fallback: episode_advantage_or_zero

```

如果 action-distribution route 工程成本太高，临时降级：

```

encoder: text_embedding
prefilter.same_stage: true
prefilter.compatible_action_mask: true

```

但这只能作为 pipeline smoke，不应视为最终理论路线。

11. 和用户原问题的关系

用户的担心是对的：agent 的行为依赖 trace，而不是单个 observation。因此：

- anchor_obs exact match 太窄；
- anchor_obs text similarity 仍然不够；
- 应该以 pre-action history h_t 为 state；
- soft matching 应该比较 histories 的 decision/predictive equivalence。

如果 actor 确实有“既视感”，它不应该只表现为 hidden cosine，而应该表现为：

histories	actor	action
actor/probe	future transition	/ return

这才是可以从理论上站住的 soft route。

12. 最终建议

Soft-GiGPO 最合理的第一条路线是：

```

same uid
-> history-level state, not observation-only
-> stage/action-mask prefilter
-> frozen actor action-distribution distance
-> top-k leave-one-out weighted baseline
-> confidence gate
-> hard group fallback / episode fallback

```

不建议第一版做：

- 跨 uid matching；
- raw hidden cosine 直接进 advantage；

- online actor hidden 不冻结;
- value-only matching;
- external judge scalar 直接做 step reward;
- 一次性合并 value head、Soft-GiGPO、StepPPO action-level ratio。

一句话总结:

Soft-GiGPO 可行，但理论依据不是“语义相似”，而是“近似 value-equivalence / bisimulation-equivalence / predictive-state equivalence”。第一版应把这种等价落实到 actor action-distribution + environment stage/action mask 上。

13. 参考资料

相关 PDF 已归档到:

EXPS/papers/021_soft_state_matching_theory/

核心参考:

- Ferns, Panangaden, Precup: Metrics for Finite Markov Decision Processes.
- Li, Walsh, Littman: Towards a Unified Theory of State Abstraction for MDPs.
- Dayan: Improving Generalisation for Temporal Difference Learning: The Successor Representation.
- Littman, Sutton, Singh: Predictive Representations of State.
- Feng et al.: Group-in-Group Policy Optimization for LLM Agent Training.
- Zhu et al.: GAGPO: Generalized Advantage Grouped Policy Optimization.
- Choi et al.: Your Language Model is Its Own Critic.
- Liu et al.: Agentic Reinforcement Learning with Implicit Step Rewards.