

022: Self-Summary Credit Assignment: 用轨迹自总结连接长程 Agent RL 的过程监督与策略改进

2026-06-26

摘要

本文将一个新的长程 Agent RL 训练思路整理为可落地实验方案：在 rollout 中显式插入由 actor 自己生成的 summary / policy-improvement note，形成

```
prompt -> traj1 -> summary -> traj2 -> reward
```

其中 summary 不是旁路日志，而是一个可训练的中间动作。它一方面被后续 **traj2** 的 reward 训练，另一方面可以作为 hindsight condition 反过来评价 **traj1** 中哪些 step / token / action 更值得强化或抑制。本文暂称该方向为 **Self-Summary Credit Assignment, SSCA**。

本文定位不是替代 GiGPO / GAGPO / StepPPO，而是补充一个新的 credit source：当 exact same-state grouping 稀疏、local rerollout 昂贵、critic 学习慢时，利用“summary-conditioned policy shift”给 prefix trajectory 提供低成本的隐式过程监督。

1 核心问题

当前长程 Agent RL 的主要困难不是只有 sparse reward，而是三件事同时出现：

1. rollout 昂贵，不能为每个中间 state 大量重采样；
2. trajectory 很长，episode reward 直接广播会污染大量 routine steps；
3. state 复现稀疏，GiGPO / GAGPO 依赖的 same-state group 在开放式环境中不稳定。

已有方案大致分成三类：

- **Within-batch step credit**: GiGPO / GAGPO 用同状态或 grouped value proxy 从当前 batch 中构造 step-level advantage。
- **Reflection / retry training**: Reflexion、Self-Refine、Reflect, Retry, Reward 证明反思可以改善下一次尝试。
- **Policy-implied dense credit**: VIMPO、SC-GRPO、SDPO 用 policy log-ratio 或 self-conditioned distribution shift 提供 token-level credit。

SSCA 的切口是把这三条线合并：

summary 不只是给后续决策用的上下文，也可以作为 prefix trajectory 的 hindsight policy condition，从而构造 prefix-level / step-level / token-level 的隐式 advantage 和 value target。

2 Rollout 结构

对同一个任务 prompt x , 将一条 trajectory 切成三段:

$$\tau = (\tau_1, \sigma, \tau_2). \quad (1)$$

其中:

- $\tau_1 = (o_0, a_0, \dots, o_k, a_k)$: 前半段尝试;
- r_1 : 阶段性 feedback, 可来自 verifier、环境中间分、失败原因、工具 stderr、GUI state diff 或测试结果;
- $\sigma = \text{Summary}_\theta(\tau_1, r_1)$: actor 生成的总结、失败归因和下一步策略改进;
- $\tau_2 \sim \pi_\theta(\cdot | x, \tau_1, \sigma)$: actor 在 summary 条件下继续执行;
- $R = R(\tau_1, \sigma, \tau_2)$: suffix reward 或 final reward。

建议第一版 summary prompt 固定成结构化格式:

```
Summarize the previous trajectory using the observed feedback.
1. State belief: what is currently known?
2. Failure / success causes: which decisions helped or hurt?
3. Policy improvement: what should be done differently next?
4. Next-step plan: what should the agent do in the continuation?
```

这样做的目的不是追求漂亮自然语言, 而是让 summary 的信息密度、可验证性和可训练性更稳定。

3 训练目标

3.1 目标一: 用 suffix reward 训练 summary 和 traj2

最直接的目标是让 summary 和后续动作共同解释 suffix improvement。定义 prefix-conditioned advantage:

$$A_{\text{suffix}} = R(\tau_1, \sigma, \tau_2) - b(x, \tau_1). \quad (2)$$

这里 baseline 不应只用同 prompt group mean。更合理的是估计“给定同一个 prefix, 不靠当前 summary 时的 continuation 期望”:

$$b(x, \tau_1) \approx \mathbb{E}[R | x, \tau_1, \text{no summary/generic summary}]. \quad (3)$$

第一版可以分三档实现:

版本	baseline	优点	风险
V0	prompt group mean	最简单, 便于 smoke test	prefix quality 和 summary quality 混在一起
V1	同一 τ_1 下多条 continuation	因果更干净	需要额外 rerollout
V2	$V_\phi(x, \tau_1)$	rollout 成本低	value 早期不稳

suffix loss 可写为:

$$\mathcal{L}_{\text{suffix}} = - \sum_{t \in \sigma \cup \tau_2} \text{clip_ratio}_t \cdot \text{sg}(A_{\text{suffix}}). \quad (4)$$

为了避免空泛 summary 被 final reward 顺带奖励，建议加 gate：

$$g_{\text{useful}} = \mathbf{1}[R(\tau_2) > b(x, \tau_1)] \quad (5)$$

或更严格地只奖励“ τ_1 失败但 τ_2 成功”的 summary。这与 Reflect, Retry, Reward 的经验一致：只有能把 retry 变好的 reflection 才值得奖励。

3.2 目标二：用 summary-conditioned shift 监督 traj1

VIMPO 用 policy-reference log-ratio 构造 policy-implied value / advantage：

$$\rho_t = \beta \log \frac{\pi_\theta(a_t | s_t)}{\pi_{\text{ref}}(a_t | s_t)}. \quad (6)$$

SSCA 的关键替换是：不把分母设为固定 reference，而是构造同一模型在两个上下文下的 counterfactual policy：

$$\pi_{\text{now}}(a_t | h_t) = \pi_\theta(a_t | x, h_t), \quad (7)$$

$$\pi_{\text{sum}}(a_t | h_t, \sigma) = \pi_\theta(a_t | x, \sigma, h_t). \quad (8)$$

其中 h_t 是 **traj1** 的 prefix。定义 summary-conditioned log-ratio：

$$\Delta_t^{\text{sum}} = \log \pi_{\text{sum}}(a_t | h_t, \sigma) - \log \pi_{\text{now}}(a_t | h_t). \quad (9)$$

直觉是：如果模型看到 summary 后更认可 **traj1** 的某个动作，则 $\Delta_t^{\text{sum}} > 0$ ；如果 summary 暗示该动作是错误分叉，则 $\Delta_t^{\text{sum}} < 0$ 。这让 summary 成为 **traj1** 的 hindsight evaluator。

为了降低自举风险，第一版不要让 numerator / denominator 同时反传。建议采用 stop-gradient weight：

$$\mathcal{L}_{\text{prefix}} = - \sum_{t \in \tau_1} \text{sg}(g_{\text{useful}} \cdot \text{Normalize}(\Delta_t^{\text{sum}})) \log \pi_\theta(a_t | h_t). \quad (10)$$

也可以加入 KL-centering 的 VIMPO-style 版本：

$$A_t^{\text{sum}} = \beta \Delta_t^{\text{sum}} - \beta \text{KL}(\pi_{\text{sum}}(\cdot | h_t, \sigma) \| \pi_{\text{now}}(\cdot | h_t)), \quad (11)$$

但第一版可以先用 sampled-token score、top-k KL 或 candidate-set KL 近似，避免完整 vocab KL 的额外开销。

3.3 目标三：用 summary 改善 value prediction

summary 还可以作为 value predictor 的外部信息源。最直接的 learned value 版本是：

$$V_\phi(h_t) \rightarrow \text{summary 前 expected return}, \quad (12)$$

$$V_\phi(h_t, \sigma) \rightarrow \text{summary 后 expected return}, \quad (13)$$

$$\Delta V_\phi(h_t, \sigma) = V_\phi(h_t, \sigma) - V_\phi(h_t). \quad (14)$$

如果 summary 有用，应满足：

$$\Delta V_\phi(h_k, \sigma) \approx R(\tau_2) - b(x, \tau_1). \quad (15)$$

也可以构造 VIMPO-style policy-implied value loss：

$$\mathcal{L}_{V, \text{sum}} = \left[\sum_{t \in \tau_1} \beta \Delta_t^{\text{sum}} - (R(\tau_2) - b(x, \tau_1)) \right]^2. \quad (16)$$

这条路线的含义是：summary-conditioned policy shift 的 cumulative score 应该对齐 suffix improvement。若 suffix 没有改善，累计 log-ratio 不应无条件变大。

4 完整目标与推荐分阶段实现

总目标可以写成：

$$\mathcal{L} = \mathcal{L}_{\text{suffix}} + \lambda_{\text{prefix}} \mathcal{L}_{\text{prefix}} + \lambda_{\text{value}} \mathcal{L}_V + \lambda_{\text{format}} \mathcal{L}_{\text{format}} + \lambda_{\text{kl}} \text{KL}(\pi_{\theta} \| \pi_{\text{anchor}}). \quad (17)$$

不建议第一版同时打开所有项。推荐阶段如下：

1. **SSCA-Suffix**: 只优化 summary tokens 和 traj2 actions。
2. **SSCA-PrefixWeight**: 加入 Δ_t^{sum} 作为 traj1 的 stop-grad advantage weight。
3. **SSCA-Value**: 加入 $V_{\phi}(h_t, \sigma)$ 或 $\mathcal{L}_{V, \text{sum}}$ 。
4. **SSCA-Retrieve**: 把有效 summary 写入历史经验库，形成跨 batch memory-conditioned critic。

5 推荐第一版算法

```
Algorithm: Self-Summary Policy Optimization (SSPO / SSCA)

1. Roll out tau_1 under pi_old.
2. Obtain intermediate feedback r_1.
3. Generate sigma = Summary(tau_1, r_1) under pi_old.
4. Continue rollout tau_2 under pi_old conditioned on sigma.
5. Compute suffix reward R and prefix baseline b(x, tau_1).
6. Update summary + tau_2 with A_suffix = R - b.
7. If A_suffix > 0:
    compute Delta_t^sum =
        log pi_old(a_t | h_t, sigma) - log pi_old(a_t | h_t)
    update tau_1 with stopgrad(normalized Delta_t^sum).
8. Optionally train V_phi(h_t, sigma) to predict R or A_suffix.
```

这个版本的优点是清楚、可诊断、不会过早引入复杂 critic。它把 summary 当成可训练 action，同时只在 summary 被 suffix reward 验证后才让它参与 prefix supervision。

6 和现有工作的关系

方向	代表工作	与 SSCA 的关系
Reflection / retry	Reflexion, Self-Refine, Reflect Retry Reward	证明 reflection 可以改善后续尝试; SSCA 进一步把有效 summary 反过来监督 prefix。
Policy-implied credit	VIMPO, SDPO, SC-GRPO	提供 log-ratio / self-conditioned shift 的理论和工程先例; SSCA 将 reference 换成 summary-conditioned counterfactual policy。
Agent step credit	GiGPO, GAGPO, HCAPO	提供长程 agent step-level baseline; SSCA 不依赖 exact same-state group, 而依赖 within-trajectory hindsight summary。
Memory RL	MMPO, Memory-R2	关注 summary/memory 质量和公平 credit; SSCA 用 suffix improvement + policy shift 替代或补充 belief entropy / local rerollout。
Actor-as-critic	POISE, V0.5	支持从 actor 内部状态或 prior 读 value; SSCA 可学习 summary-conditioned value。

与 VIMPO 的关键差异。 VIMPO 的 ratio 是 current policy 相对 frozen reference; SSCA 的 ratio 是 summary-conditioned current/old policy 相对 unconditioned current/old policy。因此 SSCA 不应被表述为“把 VIMPO 的 ref 换成 now”，更准确是：

用 summary 诱导同一 actor 的 counterfactual policy，再用 contextual log-ratio 作为 hindsight credit signal。

与 SC-GRPO 的关键联系。 SC-GRPO 的重要教训是：own solution 不适合直接当 distillation target，但适合当 credit filter。SSCA 应采用同样原则：

good summary is not a target; good summary is a credit filter.

也就是 reward / suffix improvement 决定更新方向，summary-conditioned shift 决定哪些 prefix step/token 值得更新。

7 实验设计

7.1 任务选择

第一批任务应满足四个条件：多步 trajectory、可验证 reward、可切分 `traj1/traj2`、summary 确实可能改善 continuation。

任务	优点	风险
Countdown / math retry	成本低, 适合验证 summary RL 与 prefix score correlation	不够 agentic
API / function calling	失败原因清晰, 和 Reflect Retry Reward 可比	环境复杂度有限
WebShop	经典 agent RL, 有 GiGPO/GAGPO 对照	state/action 模板化, summary 收益可能有限
ALFWorld	长程多步, 和现有 agent credit baseline 可比	exact state overlap 可能已经很强
Code repair / unit test	traj1 失败、summary、 traj2 修复很自然	token/action 粒度对齐较难

建议路线:

cheap retry task -> validate summary RL and prefix correlation
 WebShop / ALFWorld -> validate long-horizon agent benefit

7.2 Ablation

方法	说明
GRPO / DAPO	trajectory-level reward baseline
Reflect-Retry-Reward style	只奖励 summary/reflection tokens, 不监督 prefix
GiGPO / GAGPO	step-level agent credit baseline
SSCA-Suffix	训练 summary + traj2
SSCA-PrefixWeight	加 summary-conditioned prefix advantage
SSCA-Value	加 summary-conditioned value predictor
SSCA-NoRewardGiven	summary 不看 r_1 , 验证反馈是否必要
SSCA-RandomSummary	控制“只是增加上下文长度”的可能性
SSCA-BadSummaryGateOff	suffix 未改善时关闭 prefix supervision

7.3 诊断指标

训练前必须先做 offline diagnostics, 否则容易把错误 summary 当成监督源。

Summary usefulness.

$$\Delta R_{\text{summary}} = \mathbb{E}[R(\tau_2) \mid \text{with summary}] - \mathbb{E}[R(\tau_2) \mid \text{generic/no summary}]. \quad (18)$$

如果该值不显著, 说明 summary prompt 或任务切分本身有问题。

Prefix score correlation.

$$S_{\text{prefix}} = \sum_t \Delta_t^{\text{sum}}, \quad \Delta R = R(\tau_2) - b(x, \tau_1). \quad (19)$$

检查 $\text{corr}(S_{\text{prefix}}, \Delta R)$ 。如果相关性弱, Δ_t^{sum} 不应进入训练, 只能作为分析信号。

Key-step localization. 在有人工或规则标注的样本上，检查高 Δ_t^{sum} 是否集中在关键动作：工具选择、query reformulation、wrong branch、search/filter/compare 决策、code patch 关键行。

Summary faithfulness. 检查 summary 是否引用了 traj1 中不存在的信息。可加一个轻量 verifier：

summary claim must be supported by trajectory evidence

7.4 建议记录的 metrics

```
ssca/summary_token_len_mean
ssca/summary_useful_gate_rate
ssca/suffix_adv_mean
ssca/suffix_adv_std
ssca/prefix_delta_sum_mean
ssca/prefix_delta_sum_std
ssca/prefix_delta_reward_corr
ssca/prefix_weight_entropy
ssca/value_before_mean
ssca/value_after_mean
ssca/value_delta_reward_corr
ssca/summary_faithfulness_fail_rate
ssca/random_summary_gap
```

8 主要风险与约束

Summary reward hacking. 如果只奖励 traj2, summary 可能学会模板化文本，例如“我应该更仔细”。需要 schema、长度约束、factuality verifier 和 RandomSummary ablation。

Moving-reference instability. VIMPO 的 reference 是 frozen, SSCA 的 π_{now} 和 π_{sum} 都可能随训练漂移。第一版应使用 pi_old 计算 ratio, 并对 Δ_t^{sum} stop-gradient。

Action-dependent baseline bias. 如果 $V_\phi(x, \tau_1, \sigma)$ 直接看当前 action 并作为 policy-gradient baseline, 可能引入 bias. value predictor 第一版应作为 auxiliary loss; 若用于 baseline, 应采用 cross-rollout / leave-one-out 设计。

错误 summary 污染 prefix. 如果 traj2 没改善, summary 不应 supervise prefix. prefix loss 必须被 suffix improvement gate 控制。

与 StepPPO-v3 的边界. 当前 EXPS 主线中 StepPPO-v3 是 value-head-only 实验, 不默认改变 GiGPO policy advantage、policy loss 或 rollout recipe. SSCA 应作为新的实验方向, 不应写成 v3 的默认修改。

9 预期结果

合理预期不是第一次实验就超过所有 agent RL baseline, 而是先证明三件事：

1. SSCA-Suffix 比普通 GRPO 更快学会有效 reflection / summary;
2. $\sum_t \Delta_t^{\text{sum}}$ 与 suffix improvement 有正相关;
3. 在长轨迹、routine step 多的任务上, SSCA-PrefixWeight 能提升 sample efficiency 或降低 advantage 方差。

若上述诊断成立,再推进 SSCA-Value 和历史 summary retrieval;若诊断不成立,应优先改 summary prompt、切分点、feedback 设计,而不是加更复杂的 critic。

10 参考入口

- VIMPO: <https://arxiv.org/abs/2606.20008>
- SC-GRPO / Learning from Own Solutions: <https://arxiv.org/abs/2606.18810>
- Self-Distillation Policy Optimization: <https://arxiv.org/abs/2601.20802>
- Reflect, Retry, Reward: <https://arxiv.org/abs/2505.24726>
- Reflexion: <https://arxiv.org/abs/2303.11366>
- Self-Refine: <https://arxiv.org/abs/2303.17651>
- STaR: <https://arxiv.org/abs/2203.14465>
- GAGPO: <https://arxiv.org/abs/2605.13217>
- Memory-R2: <https://arxiv.org/abs/2605.21768>
- MMPO: <https://arxiv.org/abs/2605.30159>
- HCAPO: <https://arxiv.org/abs/2603.08754>
- POISE: <https://arxiv.org/abs/2605.07579>