

024: SSCA Retry Full 实验总结

traj1 + summary + traj2 的设计、指标与失败分析

2026-06-29

摘要

本文总结当前 **SSCA retry** (Self-Summary Credit Assignment) 实验线，即用户提出的

```
traj1 + summary + traj2
```

两阶段 retry 训练方案。当前实现已经完成工程闭环：模型先在 ALFWorld 上执行第一次轨迹 **traj1**，再根据第一次轨迹和 outcome feedback 生成一个可训练的 **summary/retrymemory**，随后环境重置，第二次轨迹 **traj2** 只看到原始任务 prompt、当前 observation 和 summary，而不直接看到 **traj1** 完整历史。

结论是：**链路跑通，但核心算法假设尚未成立**。seed2026 的 full run 跑满 150 step，整体 validation success 从初始约 6.6% 提升到 30.9%；summary 格式质量从 0.296 提升到 0.759，说明模型学会了输出结构化 retry memory。但最终 **traj2** 没有超过 paired **traj1**：validation 中 **traj1_success=0.336**，**traj2_success=0.281**，retry improved rate 为 0.172，degraded rate 为 0.227，平均 **reward_delta=-0.547**。因此当前版本更多证明了“summary action 可以接入训练”，还没有证明“summary 能稳定提升后续 policy”。

1 实验目标

原始目标是把 reflection / retry 的思想做成一个真正可训练的 RL action，而不是把 summary 当作外部日志。对同一条 ALFWorld task prompt x ，rollout 被组织为：

```
traj1:   task prompt -> action_1 ... action_T -> reward1
summary: compact(traj1, reward1, feedback) -> retry memory
traj2:   reset env -> task prompt + retry memory -> action'_1 ... -> reward2
```

设计中的核心约束如下：

1. **traj1 只依赖 prompt**：第一次尝试是普通 GRPO/ALFWorld rollout，不看 summary。
2. **summary 是 actor action**：summary 由当前 policy 生成，写入 batch，参与 log-prob 和 policy loss。
3. **traj2 不看完整 traj1**：第二次尝试看不到第一轮完整 history，只能读到 summary 和 live observation。
4. **summary 由后续结果监督**：summary 的好坏不应只由格式判断，而应由它是否提升 **traj2** 决定。
5. **paired improvement 是主要信号**：核心指标不是单独的 **traj2 success**，而是同一 prompt 下 **reward2-reward1** 或 **success2-success1**。

2 当前实现结构

2.1 Rollout collector

核心 collector 是 `recipe/SSCA/rollout_loop.py` 中的 `SSCA2TrajCollector`。代码注释中当前链路是：

- `traj1`: ALFWorld task prompt → first-attempt actions;
- `summary`: compact observation trace + outcome feedback + summary prompt → retry memory;
- `traj2`: reset to initial task → ALFWorld task prompt + retry memory → retry actions。

训练数据被安排为两组标准 GRPO group：

- `traj1` rows 使用第一次尝试 reward;
- `summary+traj2` rows 共享 retry uid / traj uid, 并使用第二次尝试 reward。

这样 `summary` response tokens 和后续 `traj2` action tokens 处在同一个 retry branch 中，理论上可以通过后续 outcome 获得 credit。

2.2 Summary prompt

当前 `summary` instruction 要求输出固定五行 retry memory：

```
Task: <task phrase>
Known: object=<...>; receptacle=<...>; inventory=<...>
Attempt1: tried=<...>; bad=<...>; errors=<...>
Plan: first=<...>; backup=<...>; after_object=<...>
Rule: one admissible command per action; no or/and-then/list actions; no invented names
```

Prompt 约束包括：

- 只能基于 task、compact first attempt trace 和 outcome feedback;
- 未观察到的信息必须写 `notobserved` 或 `unknown`，不能发明对象或位置;
- plan verb 必须接近 ALFWorld admissible command，例如 `goto`、`open`、`take`、`put`、`clean`、`heat` 等;
- 不允许 markdown、bullet、wrapper tag、额外解释;
- 总长度限制约 90 words。

这版 prompt 是从 023 文档中的人工 review 循环改出来的，目标是降低早期 full trajectory dump 带来的 hallucination 和不可执行 plan。

2.3 Summary 输入上下文

默认 `summary` context mode 是 `compact_obs_trace`。每个 `summary` prompt 包含三类信息：

1. **Task / initial scene**: 从 ALFWorld 初始 observation 或 anchor 中抽取任务目标和初始场景;
2. **Compact first attempt trace**: 只保留最多若干个关键 step 的 observation、action output、parsed action、reward、done、valid flag、env feedback;

3. **Outcome feedback**: 包括 attempt status、final environment reward、episode length、invalid action count、won flag、goal-condition success rate 和 final observation。

相比旧版 full trajectory dump, compact trace 不再把完整 prompt、长 history、admissible action list 和截断碎片全部塞给模型，避免 summary 被噪声诱导。

2.4 traj2 prompt

环境 reset 后, traj2 的 observation 会被拼接为:

```
<current ALFWorld observation / original task prompt>

[Retry memory generated from the first attempt]
<summary text>

Retry context contract: use the current ALFWorld observation plus this retry memory only. Treat
the retry as starting from the initial scene; choose exactly one admissible action.
```

因此, traj2 的信息契约是: 只能使用当前 live observation 和 summary。summary 是对第一次尝试经验的压缩, 而不是完整轨迹复制。

2.5 训练 batch 和 reward 组织

一次 SSCA rollout 结束后, 会先收集 traj1 rows, 再收集 summary+traj2 rows。关键 metadata 包括:

- `ssca_phase`: traj1、summary 或 traj2;
- `ssca_summary_is_policy_action`: 只在 summary row 为 true;
- `ssca_linked_first_traj_uid`: summary/traj2 指向 paired traj1;
- `ssca_env_episode_rewards`: 原始环境 reward, 不含 summary 结构 bonus;
- `ssca_reward_bonus`: summary row 的格式质量 shaping reward, 仅训练时启用;
- `ssca_context_contract`: 标记该 row 的可见上下文约束。

主要 metrics 在 rollout 阶段统计:

- `ssca_traj1_success_rate / ssca_traj2_success_rate`;
- `ssca_retry_improved_success_rate / ssca_retry_degraded_success_rate`;
- `ssca_metric/retry/reward_delta_mean`;
- `ssca_metric/summary/quality_mean`;
- `ssca_metric/summary/quality_reward_corr`。

2.6 Summary quality score

Summary quality parser 主要检查:

- 五个 label 是否都出现;

- 是否严格按五行顺序输出；
- word count 是否不超过上限；
- 是否没有 <think>、<action>、markdown wrapper、bullet list；
- Plan: 是否包含 first=、backup=、after_object=；
- first= 是否以允许的 ALFWorld command prefix 开头；
- 是否避免 check/inspect/search/verify/tryto 这类非 admissible-action 风格词；
- task terms 和 summary 是否有 overlap。

训练时 summary row 会获得小的结构 bonus:

$$r_{summary_bonus} = \alpha \cdot q(summary), \quad \alpha = 0.2. \quad (1)$$

Validation 时该 bonus 关闭。

3 VIMPO-style value loss

为了进一步约束 “traj2 policy 应该好于 traj1 policy”，当前实现加入了一个 critic-free 的 VIMPO-style auxiliary loss。

3.1 Target 构造

在 paired prompt 内，使用第一次尝试作为 outcome baseline:

$$\Delta r = r_2 - r_1. \quad (2)$$

实际 target 为:

$$y_{branch} = \frac{\Delta r + m}{s}, \quad (3)$$

其中默认 margin $m = 0.1$, reward scale $s = 10.0$, target clip 为 2.0。

当前默认 target_distribution=split_by_retry_rows, 即 branch-level target 被分摊到 summary row 和 traj2 rows 上。

3.2 Loss 形式

VIMPO-style loss 的实现形式为:

$$\mathcal{L}_{vimpo} = \frac{1}{2} \left[\sum_t \beta (\log \pi_\theta(a_t|s_t) - \log \pi_{ref}(a_t|s_t) - \text{sg}[KL_t]) - y \right]^2. \quad (4)$$

默认 $\beta = 0.01$, value_loss_coef=0.05, loss type 为 Huber。该 loss 只在 summary/traj2 rows 上激活。

这里的 pi_ref 是同一 state/action 下的 reference model log-prob, 不是 traj1 的 token log-prob。原因是 traj1 和 traj2 的 state/action 通常不同, 不能逐 token 对齐。paired traj1 reward 只作为 outcome baseline 进入 $r_2 - r_1$ target。

4 Full 训练配置

当前 full 脚本为：

```
scripts/run_ssca_retry_grpo_alfworld_1p5b_full.sh
scripts/run_ssca_retry_grpo_alfworld_1p5b_full_3seeds.sh
```

配置项	当前值
Model	Qwen/Qwen2.5-1.5B-Instruct
Task	alfworld/AlfredTWEEnv
GPU	4
Engine	vllm
Tensor parallel	2
Train / val data size	16 / 128
Train batch size	16
Group size	8
Max env steps	50
Total steps	150
Test freq	5
Actor lr	1e-6
KL loss	enabled, coef 0.01
Invalid action penalty	enabled, coef 0.1
Flash attention	flash_attention_2
Ray CPUs / env worker CPUs	60 / 0.1
Heavy trace dump	disabled

SSCA / VIMPO 配置项	当前值
Summary context mode	compact_obs_trace
Summary trace max steps	6
Summary step obs chars	240
Summary feedback chars	240
Summary max prompt chars	1200
Summary max chars	1200
Summary quality reward coef	0.2
Summary quality max words	110
Retry same seed	True
VIMPO enable	True
VIMPO beta	0.01
VIMPO value loss coef	0.05
VIMPO target distribution	split_by_retry_rows
Value head	disabled

5 关键参数定义与物理意义

本节补充 review 后认为必须明确的参数口径。前文的配置表给出了数值，但如果不解释这些参数在 rollout、优化和资源使用中的物理意义，读者很难判断实验是否与 GRPO / GraphGPO 可比，也很难定位为什么 summary 学到了格式但没有提升 retry outcome。

5.1 数据、rollout 与训练规模参数

参数	当前值	定义	物理意义 / 对实验的影响
TRAIN_DATA_SIZE	16	数据预处理阶段抽取的 train task 数, 写入 train parquet。	决定一个 epoch 内可见的不同 ALFWorld task 数。当前只有 16 个 task, 因此 150 step 更接近小任务集上的反复训练, 容易让 <code>traj1</code> 快速变强, 也更容易出现 retry branch 被强 first attempt 压制。
VAL_DATA_SIZE	128	validation parquet 中的 task 数, 同时作为 <code>data.val_batch_size</code> 。	validation 每次覆盖 128 个任务。SSCA validation 每个任务要执行 <code>traj1+summary+traj2</code> , 因此一次 validation 成本远高于普通 GRPO。
TRAIN_BATCH_SIZE	16	每个训练 step 读取的 prompt/task 数。	这是 prompt 级 batch size, 不等于最终 actor update rows。SSCA 中每个 prompt 会展开为 paired first/retry branch, 实际训练 token 数约翻倍, 并额外包含 summary row。
GROUP_SIZE	8	<code>env.rollout.n</code> , 同一 prompt 的 GRPO group size。	决定每个 task 的并行采样数和 advantage group。对 SSCA 来说, 每个 group 内还会形成 paired <code>traj1</code> 与 <code>summary+traj2</code> 。group 越大, GRPO baseline 越稳定, 但 rollout 成本线性上升。
MAX_ENV_STEPS	50	单条 ALFWorld episode 最多环境交互步数。	控制 <code>traj1</code> 和 <code>traj2</code> 各自最长长度。SSCA 最坏情况下每个 prompt 需要约 2*50 个环境动作外加一次 summary generation, 因此 step 时间显著高于 GraphGPO。
TOTAL_EPOCHS	150	当前脚本中等价于 total training steps。	决定最终训练长度。由于 train task 只有 16 个, 150 step 足以让 <code>traj1</code> 在训练集上变强, 这会改变 retry target 分布, 使大量 paired delta 变负。
TEST_FREQ	5	每隔多少 training step 跑一次 validation。	频繁 validation 提供密集曲线, 但 SSCA validation 非常贵, 最终 step 中 <code>timing_s/testing=274.708</code> , 显著增加 wall-clock。
VAL_BEFORE_TRAIN	True	训练前先跑一次 validation。	提供 step0 baseline, 使 summary quality 和 success rate 的提升可被量化。

5.2 模型、优化与资源参数

参数	当前值	定义	物理意义 / 对实验的影响
MODEL_PATH	Qwen2.5-1.5B-Instruct	actor/ref 初始化模型。	决定初始 ALFWorld 指令跟随和 admissible-action 格式能力。1.5B 可跑通但规划能力有限，summary 信息融合可能弱于更大模型。
actor.optim.lr	10^{-6}	actor 参数学习率。	日志中显示 actor/lr:0.000 是格式化舍入，不表示 lr 为零。该 lr 较保守，有利于稳定，但对新引入的 summary behavior 学习可能偏慢。
actor.use_kl_loss	True	actor update 中加入 reference KL loss。	约束 policy 不要偏离初始模型过远。对 SSCA 的副作用是 summary/retry 新行为需要在 KL 约束下学习，若信号弱，可能只学到格式而不改变 action policy。
actor.kl_loss_coef	0.01	KL loss 权重。	KL 越大，policy 越保守；越小，policy 更自由但风险更高。当前值沿用 GRPO/GiGPO 风格，主要保证稳定性。
invalid_action_penalty_coef	0.1	无效动作 penalty 系数。	ALFWorld 中 admissible action 是硬约束。该项鼓励模型输出可执行动作；但 summary 本身不是 env action，因此它主要约束 traj1/traj2 action rows。
max_response_length	512	单次模型响应最大 token 数。	action response 一般较短，但 summary generation 也走同一个 rollout 接口。上限过大可能允许 verbose summary，过小可能截断五行 memory。
tensor_model_parallel_size	2	vLLM rollout 的 tensor parallel size。	影响 rollout generation 的显存和吞吐。SSCA step 中 generation 是主要耗时之一，最终 timing_s/gen=233.660。
gpu_memory_utilization	0.6	vLLM 可占用 GPU 显存比例。	留出训练/FSDP/缓存空间，降低 OOM 风险；过低会限制 vLLM batch 效率。
RAY_NUM_CPUS	60	Ray 可用 CPU 总量。	防止占满整机 CPU。SSCA 有双 episode rollout 和 validation，CPU 主要被环境 worker、Ray 调度、data-loader 使用。
ENV_WORKER_CPUS	0.1	每个 env worker 声明的 CPU resource。	允许较多 ALFWorld env 并发。值过高会导致 Ray 排队，过低可能过度超卖 CPU。当前值参考之前 GRPO/-GraphGPO 的可运行配置。
RL_TRACE_*	heavy trace off	控制是否 dump DataProto/token/prob 级 trace。	heavy trace 会显著拖慢训练和占用 IO。full 中关闭 token/prob array dump，只保留轻量 rollout text，是为了解决此前 dump 过慢问题。

5.3 SSCA summary 参数

参数	当前值	定义	物理意义 / 对实验的影响
summary_context_mode	compact_obs_trace	summary 看到的 traj1 上下文格式。	物理意义是“把第一次尝试压缩成环境证据”，避免 full prompt trace 的递归 history 和 admissible list 噪声。
summary_trace_max_steps	6	summary 输入中最多保留的 traj1 step 数。	控制证据带宽。太小会漏掉关键搜索轨迹；太大又会引入噪声和长 prompt。当前 6 是 prompt review 后的折中。
summary_step_obs_chars	240	每个 step observation 截断字符数。	控制每步环境状态的可见细节。过短可能丢目标物/容器；过长会挤占 token budget。
summary_step_feedback_chars	240	每步 env feedback 截断字符数。	保留 invalid reason、目标达成提示、final observation 等关键信息。
summary_max_prompt_chars	1200	summary prompt 中初始场景/上下文的最大字符数。	限制 summary action 的输入规模，使 summary 任务更像 evidence extraction 而不是长文阅读。
summary_max_chars	1200	放入 traj2 prompt 的 summary 最大字符数。	防止 summary 过长污染 traj2 prompt。当前上限仍较宽，实际 word limit 由 quality parser 和 prompt 控制。
summary_quality_reward_coef	0.2	summary 结构质量 bonus 系数。	这是格式 shaping，不是 outcome reward。它解释了为什么 summary quality 能快速提高；但若权重相对 outcome 过强，会鼓励“格式漂亮但无用”的 memory。
summary_quality_max_words	110	quality parser 的 word limit。	防止 summary 变成长篇 reflection。最终 word count 约 89.9，说明长度约束生效。
retry_same_seed	True	retry reset 是否回到同一任务实例/seed。	保证 reward2-reward1 是 paired comparison，而不是换了环境导致的随机差异。该参数对 credit assignment 是关键前提。

5.4 VIMPO-style 参数

参数	当前值	定义	物理意义 / 对实验的影响
SSCA_VIMPO_ENABLE	True	是否启用 paired-improvement auxiliary loss。	这是让 retry branch 显式对齐 reward2-reward1 的尝试；若关闭，summary 主要依赖 GRPO outcome reward 和结构 bonus。
reward_scale	10.0	把环境 reward delta 缩放到 value target 的分母。	ALFWorld 成功 reward 量级约 10，除以 10 后 target 约落在 $[-1, 1]$ 。物理意义是把任务 reward 转成 log-ratio/value loss 可处理的数值尺度。
margin	0.1	在 reward2-reward1 上加的正 margin。	表示希望 retry branch 不只是持平，而是略好于 first branch。scaled 后约为 0.01，当前很弱。
target_clip	2.0	value target 截断范围。	防止极端 reward delta 造成过大 auxiliary loss。当前日志中 target_clip_count=0 ，说明没有实际触发。
target_distribution	split_by_retry_rows	branch target 如何分配到 summary/traj2 rows。	当前把 branch-level target 分摊给 summary row 和所有 traj2 action rows。优点是稳定，缺点是 summary 获得的直接监督被稀释。
beta	0.01	VIMPO implied value 中 log-ratio 项的温度/尺度。	决定 policy-reference log-ratio 转成 value 的幅度。过小会使 value signal 很弱；当前最终 value-target corr 几乎为 0，提示该项可能偏弱。
value_loss_coef	0.05	VIMPO auxiliary loss 加入 actor loss 的权重。	控制 paired-improvement signal 相对 GRPO policy loss / KL loss 的强度。当前保守，可能不足以改变 summary 行为。
detach_kl	True	loss 中 KL 项是否 stop-gradient。	保留 VIMPO 的低方差 baseline 作用，避免模型通过直接操纵 KL 项走捷径降低 loss。
value_loss_type	Huber	residual loss 类型。	Huber 对 outlier 比 squared error 稳定。当前 reward delta 分布有较大方差，因此 Huber 更安全。
value_head_enable	False	是否启用独立 learned value head。	当前为 critic-free VIMPO-style loss，不训练额外 value head。这样更轻量，但 value 表达完全依赖 policy/ref log-ratio。

6 关键指标定义与判读口径

指标	定义	如何判读
val/success_rate	validation 中所有展开 episode 的平均成功率。SSCA 中包含 first/retry 分支的聚合口径。	衡量整体任务表现，但不能单独证明 summary 有用；必须结合 traj1/traj2 paired 指标。
val/ssca_traj1_success_rate	validation 中 first attempt 的成功率。	反映没有 summary 时当前 policy 的能力，是 retry 的 paired baseline。
val/ssca_traj2_success_rate	validation 中 summary-conditioned retry attempt 的成功率。	反映 summary+retry prompt 后的能力。若该值长期低于 traj1，说明 retry memory 没有产生净收益。
ssca_retry_improved_success_rate	paired 样本中 success2>success1 的比例。	衡量 retry 是否把失败变成功。它比总体 success 更直接反映 SSCA 目标。
ssca_retry_degraded_success_rate	paired 样本中 success2<success1 的比例。	衡量 retry 是否把成功变失败。当前 degraded 大于 improved，是主要负信号。
ssca_metric/retry/reward_delta_mean	paired 平均 $r_2 - r_1$ 。	SSCA 的核心 outcome 指标。正值才表示 retry branch 平均优于 first branch；当前最终仍为负。
ssca_metric/traj*_valid_action_ratio	有效动作比例，约等于 $1 - invalid/length$ 。	如果 traj2 valid ratio 低于 traj1，说明 summary 或 retry prompt 可能干扰 admissible-action selection。
summary/quality_mean	结构化 summary parser 给出的格式质量分数。	只代表格式和基本 grounding，不代表 outcome 有用。它需要和 reward corr / improvement 一起看。
summary/five_label_rate	五个指定 label 是否完整出现的比例。	衡量 prompt following。该值提升说明模板学会了，但不能证明 retry 策略有效。
summary/plan_ok_rate	Plan:first= 是否符合 ALFWorld command 风格等约束。	衡量 plan 行是否可执行风格。最终接近 1，说明格式约束有效。
summary/quality_reward_corr	summary quality 与 retry reward 的相关性。	若接近 0 或为负，说明 summary 格式分数和真正任务收益脱钩。当前为负，是最关键诊断之一。
actor/ssca_vimpo_value_target_corr_active	VIMPO implied value 与 paired target 的相关性。	衡量 auxiliary value loss 是否学到方向。当前约 0.003，说明没有学到有效 improvement signal。
actor/ssca_vimpo_sign_acc_active	implied value 和 target 正负号一致率。	若接近 0.5，等价随机方向判断。当前 0.488，说明 value loss 没有可靠区分 improved/degraded branch。
timing_s/step	一个 training step 的 wall-clock 时间。	SSCA 每步包含双 episode 和 summary generation，因此不能直接与 GraphGPO step time 等价比较。

7 分析充分性 review

从 review 角度看，当前报告需要回答三个层面的问题：

- 实现是否符合设计：**是否确实执行了 traj1->summary->reset->traj2，summary 是否作为 policy action 进入训练，traj2 是否只看到 summary 而不是完整 traj1。
- 指标是否覆盖核心假设：**是否同时报告 overall success、traj1/traj2 paired success、reward delta、summary quality、summary-outcome correlation 和 VIMPO target learning。
- 失败原因是否能被定位：**是否能区分“summary 格式没学会”、“summary 学会但没用”、“traj2 prompt 干扰动作”、“VIMPO signal 太弱”、“成功 traj1 导致自然退化”等不同机制。

补充上述参数和指标定义后，文档现在基本覆盖了这三层。仍然不足的是：日志中缺少按 traj1_failed / traj1_success 分桶后的 retry 指标，也缺少 summary 内容级别的自动统计，例如是否包含目标物、目标容器、第一步 plan 是否在 admissible action 中。因此本文的机制判断是由现有 aggregate metrics 推断出来的，下一版实验应把这些分桶指标直接打进日志。

8 运行记录

当前保留下来的 SSCA full 运行主要是 seed2026:

Run	Seed	状态	日志
Early SSCA retry	2026	跑到 step 56/150 后中断	logs/ssca_retr y_grpo_qwen25_ 15b_alfworld_f ull_seed2026_2 0260626_164746 .log
SSCA + VIMPO full	2026	跑满 150/150; final validation 后 DataLoader worker 被 kill	logs/ssca_retr y_grpo_qwen25_ 15b_alfworld_f ull_seed2026_s sca_vimpo_full _20260626_2332 43_20260626_23 3243.log

没有看到 seed2077、seed2501 的完整 SSCA full 日志。因此下面的结论只代表 seed2026，不是 3-seed 稳健结论。

9 Validation 曲线

下表来自 SSCA + VIMPO full seed2026。重点观察三类信号：总体成功率、traj1/traj2 paired 对比、summary 质量。

Step	Score	Succ	T1 succ	T2 succ	Improve	Degrade	Δr	SumQ	5-label	PlanOK	Corr
0	0.328	0.066	0.086	0.047	0.023	0.062	-0.391	0.296	0.148	0.094	0.113
5	0.264	0.062	0.086	0.039	0.039	0.086	-0.469	0.493	0.547	0.219	-0.093
10	0.604	0.109	0.133	0.086	0.078	0.125	-0.469	0.539	0.711	0.297	-0.114
15	0.307	0.082	0.109	0.055	0.047	0.102	-0.547	0.605	0.758	0.125	0.032
25	0.492	0.121	0.203	0.039	0.031	0.195	-1.641	0.625	0.750	0.305	-0.057
50	1.107	0.230	0.281	0.180	0.109	0.211	-1.016	0.705	0.695	0.758	0.026
75	1.124	0.254	0.297	0.211	0.125	0.211	-0.859	0.749	0.742	0.961	0.002
100	1.022	0.223	0.258	0.188	0.102	0.172	-0.703	0.751	0.734	0.969	0.005
125	0.839	0.180	0.219	0.141	0.109	0.188	-0.781	0.760	0.734	0.992	-0.133
150	1.203	0.309	0.336	0.281	0.172	0.227	-0.547	0.759	0.734	0.992	-0.061

表中缩写：Score 是 val/text/test_score, Succ 是 val/success_rate, T1/T2succ 是 traj1/traj2 success, SumQ 是 summary quality, Corr 是 summary quality 与 retry reward 的相关性。

10 最终 step 指标

10.1 整体任务指标

最终 step150 的整体指标如下：

Metric	Value
val/text/test_score	1.203
val/success_rate	0.309
episode/success_rate	0.605
episode/reward/mean	6.071
response_length/mean	110.699
prompt_length/mean	617.534
timing_s/step	610.902
timing_s/testing	274.708
perf/throughput	2212.467

日志中 actor/lr 显示为 0.000, 这是 console 三位小数格式导致; 脚本中的真实 lr 是 $1e-6$ 。

10.2 traj1 vs traj2

最终 validation 中, paired retry 没有超过 first attempt:

Metric	Value
val/ssca_traj1_success_rate	0.336
val/ssca_traj2_success_rate	0.281
val/ssca_retry_improved_success_rate	0.172
val/ssca_retry_degraded_success_rate	0.227
val/ssca_metric/traj1/reward_mean	3.359
val/ssca_metric/traj2/reward_mean	2.812
val/ssca_metric/retry/reward_delta_mean	-0.547
val/ssca_metric/traj1/length_mean	37.219
val/ssca_metric/traj2/length_mean	41.195
val/ssca_metric/traj1/valid_action_ratio	0.998
val/ssca_metric/traj2/valid_action_ratio	0.994
val/ssca_metric/traj1/invalid_count_mean	0.109
val/ssca_metric/traj2/invalid_count_mean	0.250

训练 batch 侧的差距更明显:

Metric	Value
episode/ssca_traj1_success_rate	0.797
episode/ssca_traj2_success_rate	0.414
episode/ssca_retry_improved_success_rate	0.070
episode/ssca_retry_degraded_success_rate	0.453
episode/ssca_metric/traj1/reward_mean	7.969
episode/ssca_metric/traj2/reward_mean	4.141
episode/ssca_metric/retry/reward_delta_mean	-3.828

这说明随着训练推进, traj1 已经相当强, 而 summary-conditioned traj2 反而经常不如第一次尝试。

10.3 Summary 质量指标

最终 validation 的 summary 质量如下：

Metric	Value
val/ssca_metric/summary/quality_mean	0.759
val/ssca_metric/summary/quality_std	0.079
val/ssca_metric/summary/label_count_mean	4.453
val/ssca_metric/summary/five_label_rate	0.734
val/ssca_metric/summary/ordered_five_line_rate	0.000
val/ssca_metric/summary/plan_ok_rate	0.992
val/ssca_metric/summary/word_count_mean	89.898
val/ssca_metric/summary/bonus_mean	0.000
val/ssca_metric/summary/quality_reward_corr	-0.061

解读：summary 的格式确实被训练起来了。quality_mean 从 0.296 到 0.759, five_label_rate 从 0.148 到 0.734, plan_ok_rate 从 0.094 到 0.992。问题在于 quality_reward_corr=-0.061，说明“格式好”并不等于“能提升 retry reward”。

10.4 VIMPO-style loss 指标

最终 step150 的 VIMPO 指标如下：

Metric	Value
actor/ssca_vimpo_value_loss	0.000
actor/ssca_vimpo_value_loss_raw	0.002
actor/ssca_vimpo_value_loss_x1e4	0.761
actor/ssca_vimpo_value_loss_raw_x1e4	15.214
actor/ssca_vimpo_active_row_ratio	0.570
actor/ssca_vimpo_terminal_value_mean_active	-0.018
actor/ssca_vimpo_terminal_target_mean_active	-0.019
actor/ssca_vimpo_rmse_active	0.070
actor/ssca_vimpo_mae_active	0.049
actor/ssca_vimpo_value_target_corr_active	0.003
actor/ssca_vimpo_sign_acc_active	0.488
actor/ssca_vimpo_target_positive_rate_active	0.414
actor/ssca_vimpo_value_positive_rate_active	0.540

value_target_corr_active=0.003 和 sign_acc_active=0.488 接近随机，说明 VIMPO implied value 没有有效学到 paired retry improvement。这个 auxiliary loss 虽然接入了，但当前权重、target 分摊和 reward delta 分布都没有形成足够强的优化信号。

11 与 GraphGPO 的参照

同 seed2026 的 GraphGPO ALFWorld full 日志为：

```
logs/graphgpo_qwen25_15b_alfworld_full_seed2026_20260622_051648.log
```

其最终 step150 约为：

Run	val/success_rate	episode/success_rate	timing_s/step
GraphGPO seed2026	0.883	0.906	235.068
SSCA + VIMPO seed2026	0.309	0.605	610.902

这不是严格公平的算法比较，因为 SSCA 每个 prompt 要执行 `traj1+summary+traj2`，rollout 和 validation 成本更高，batch 组织也不同。但它说明：当前 SSCA 版本尚不能作为 GraphGPO/GRPO 的有效替代或增强。

12 问题分析

12.1 Summary 学会了格式，但没学到 outcome-useful memory

最关键的矛盾是：summary quality 提升明显，但 reward correlation 接近 0 或为负。当前 quality reward 更像是在优化“是否像一个合格表格/模板”，而不是“是否真的帮助第二次尝试”。因此模型会越来越会写五行 summary，但这五行不一定包含能改变 action trajectory 的有效信息。

12.2 traj2 prompt 更复杂，可能干扰 action policy

traj2 比 traj1 多读一段 retry memory，prompt 更长，且必须在 live observation 和 memory 之间做信息融合。最终 `traj2_invalid_count_mean=0.250` 高于 `traj1_invalid_count_mean=0.109`，说明 summary 可能增加了无效动作或错误动作选择的概率。即使 summary 格式正确，如果其中的 plan 过时、不够 grounded，或者被模型当成硬指令复制，都会让 traj2 走偏。

12.3 成功 traj1 后再 retry 会自然产生退化样本

当前所有 prompt 都执行 retry，不管 traj1 是否已经成功。训练后期 traj1 本身越来越强，很多 paired 样本中 traj1 已经成功；此时 traj2 只有重复成功才算不退化。最终 train 侧 `traj1_success=0.797`，`traj2_success=0.414`，因此大量样本给出负 delta。这个设定会把训练目标从“失败后总结经验并改善”变成“不要比一个已经成功的首次尝试差”，难度更高且噪声更大。

12.4 VIMPO target 对 summary 的直接监督偏弱

当前 branch target 被分摊到 summary row 和所有 traj2 action rows。summary 是 retry branch 的条件变量，但它只拿到被分摊后的一小部分 target；而且 `beta=0.01`、`value_loss_coef=0.05` 都比较保守。最终 VIMPO 相关性指标没有起来，说明这个辅助项尚未有效地把 `reward2-reward1` 转化为可学习的 summary/token credit。

12.5 运行结束不干净，但指标可用

SSCA + VIMPO full 在打印 final validation metrics 和 progress 100% 后出现：

```
RuntimeError: DataLoader worker (...) is killed by signal: Killed.
```

该错误发生在 final validation 之后，因此不影响已记录指标；但说明长时间运行后的 DataLoader / Ray worker 清理仍需要处理。

13 当前结论

当前版本可以得出以下结论：

1. 工程链路成立：traj1->summary->traj2 可以完整跑通，summary 作为 actor action 进入训练。
2. Prompt 改造有效：五标签、plan 约束、word limit 等 summary 格式指标明显改善。
3. 核心算法目标未达成：traj2 没有比 paired traj1 更好，retry 平均 delta 仍为负。
4. VIMPO-style value loss 已接入，但尚未学到有效的 paired improvement value。
5. 目前不建议直接扩大到 3 seed 作为正式结果；更合理的是先改 retry gating 和 summary credit，再重新 smoke/full。

14 下一版建议

14.1 只对失败或低分 traj1 启动 retry 训练

当前所有样本都 retry，成功 traj1 会制造大量自然退化样本。下一版建议：

- 对 $\text{reward1} \leq \text{threshold}$ 的样本启用 summary+traj2 主训练；
- 对成功 traj1 可以不 retry，或只作为 preserve-plan 辅助分析，不进入主要 policy loss；
- metrics 按 traj1_failed 和 traj1_success 分桶报告。

14.2 加强 summary 的 outcome credit

可以考虑让 summary row 单独吃更强的 paired improvement signal：

- summary row 使用完整 $\text{reward2} - \text{reward1}$ target；
- traj2 action rows 继续使用 retry outcome reward；
- 或者增加 pairwise objective：improved summary 提升概率，degraded summary 降低概率。

14.3 降低结构 bonus，增加 outcome-aligned reward

结构 bonus 已经足够让格式学起来，但它和最终 reward 不相关。建议把格式 bonus 变成低权重 gate，只保证 label 完整和可解析；真正 reward shaping 应更多来自 outcome improvement，例如：

$$\text{bonus} = \alpha \cdot \max(r_2 - r_1, 0). \quad (5)$$

14.4 改 retry prompt，避免 memory 干扰动作

可以把 summary 放到更明确的 memory section，并在 action prompt 前再次强调：当前 admissible actions 和 live observation 优先，summary 只提供搜索优先级和错误规避，不是要逐字复制的动作序列。

14.5 补充诊断指标

建议新增：

- `retry_given_traj1_failed_success_rate;`
- `retry_given_traj1_success_success_rate;`
- `reward_delta_given_traj1_failed_mean;`
- `reward_delta_given_traj1_success_mean;`
- `summary_quality_given_improved_mean;`
- `summary_quality_given_degraded_mean;`
- `summary_contains_target_object_rate;`
- `summary_plan_first_is_admissible_rate。`

这些指标能回答当前最关键的问题：summary 是否真的帮助失败样本，还是只是在成功样本上增加干扰。

15 复现实验入口

单 seed full:

```
bash /prj/corp/crd/morpheus/lasvegas/china-scratch/ziyuhuan/Projects/verl-agent/scripts/  
run_ssca_retry_grpo_alfworld_1p5b_full.sh
```

三 seed 串行:

```
bash /prj/corp/crd/morpheus/lasvegas/china-scratch/ziyuhuan/Projects/verl-agent/scripts/  
run_ssca_retry_grpo_alfworld_1p5b_full_3seeds.sh
```

基于当前 seed2026 结果，更推荐先做机制修改，再运行 3-seed full。